



Universidad de Jaén

Escuela Politécnica
Superior de Jaén

Modelos de Inteligencia Artificial Sostenible para Mantenimiento Predictivo

Autor: Javier González Santos

Máster en Ingeniería Informática

Director: Prof. D. Ángel Miguel García
Departamento del director: Departamento de Informática

Fecha: 18/11/2025



CREA

AGRADECIMIENTOS

En primer lugar, quiero agradecer a Iago y principalmente a Ángel por su guía constante, su paciencia y la confianza depositada en mí durante toda la realización de este Trabajo Fin de Máster. Sus comentarios, sugerencias y exigencia técnica han sido fundamentales.

También deseo expresar mi gratitud a mi familia, especialmente a mi madre, por su respaldo inquebrantable a pesar de la distancia. Incluso estando a miles de kilómetros, su ánimo y comprensión han sido un impulso clave en los momentos de mayor esfuerzo y cansancio.

A mi familia alemana, sobre todo a Sini, por su apoyo constante, su empatía y por estar a mi lado en cada paso de este camino.

Finalmente, a mis amigos, tanto a quienes han estado cerca como a quienes me han acompañado desde otros lugares del mundo, gracias por cada mensaje, cada llamada y cada conversación que me ha ayudado a desconectar cuando era necesario y a seguir adelante cuando el proyecto parecía no avanzar.

FICHA DEL TRABAJO FIN DE TÍTULO

Titulación	Máster en Ingeniería Informática
Modalidad	Proyecto de Ingeniería
Especialidad (solo TFG)	XXXXXX
Mención (solo TFG)	XXXXXXX
Idioma	Español
Tipo	Específico
TFM en equipo	No
Autor/a	Javier González Santos
Fecha de asignación	07 de abril de 2025
Descripción corta	Este trabajo presenta ...

Índice

Índice de Figuras	VII
Índice de Tablas	IX
Siglas	XI
Resumen	1
Abstract	3
1. Introducción	5
1.1. Motivación	5
1.2. Objetivos	6
1.3. Estructura de la memoria	6
1.4. Planificación temporal	8
2. Fundamentos Teóricos y Estado del Arte	11
2.1. Evolución temporal de métodos de detección de anomalías en series temporales	11
2.2. Fundamentos estadísticos y enfoques clásicos	12
2.3. Aprendizaje profundo en la detección de anomalías	13
2.4. Redes Neuronales de Impulsos	14
2.5. Eficiencia energética	19
2.6. Arquitectura SNN base para detección de anomalías en series temporales	21

2.7. Conclusiones	25
3. Especificación del trabajo	27
3.1. Alcance	27
3.2. Hipótesis y Restricciones	27
3.3. Descripción de la solución propuesta	28
3.4. Selección de BindsNET como framework de desarrollo	29
3.5. Arquitectura del nuevo modelo híbrido	29
3.6. Preprocesamiento de datos para SNN	39
4. Resultados	43
4.1. Descripción de los escenarios experimentales	43
4.2. Metodología de evaluación	50
4.3. Análisis de resultados	51
5. Conclusiones	55
5.1. Resumen del trabajo desarrollado	55
5.2. Grado de cumplimiento de los objetivos	55
5.3. Principales contribuciones	56
5.4. Discusión de resultados	57
5.5. Limitaciones y consideraciones de validez	58
5.6. Conclusiones finales	59
5.7. Trabajos futuros	60
A. Manual de instalación y configuración técnica	62
A.1. Instalación y configuración de BindsNET	62
B. Bibliografía	65

Índice de Figuras

1.1. Diagrama de Gantt del proyecto. Fuente: Elaboración propia.	10
2.1. Ejemplo ilustrativo de una neurona LIF. Fuente: Elaboración propia. . .	18
2.2. Diagrama de la arquitectura bicapa de la SNN base. Inspirado en [1]. .	23
3.1. Flujo de datos y arquitectura SNN. Fuente: Elaboración propia.	35
3.2. Codificación y preprocesado de la señal. Fuente: Elaboración propia. .	36
3.3. Arquitectura detallada de la capa convolucional híbrida mostrando el flujo desde los impulsos de la capa B hacia el procesamiento convolucional con kernels adaptativos. Fuente: Elaboración propia. . . .	37

Índice de Tablas

1.1. Planificación temporal de tareas, con duración estimada en semanas y coste asociado.	8
2.1. Comparación entre ANNs tradicionales y SNNs	15
2.2. Comparación de rendimiento entre métodos estadísticos y redes neuronales artificiales. Fuente: [2]	19
3.1. Comparación entre modelo SNN base y modelo híbrido — Parte 1: arquitectura, conexiones y optimización.	31
3.2. Comparación entre modelo SNN base y modelo híbrido — Parte 2: evaluación, implementación y ventajas.	32
4.1. Comparativa principal de versiones de software entre TSFEDL y Proyecto SNN.	45
4.2. Resultados de detección de anomalías en dataset IOPS. N representa el número de neuronas en las capas B y C para los modelos SNN. Se muestran los mejores resultados obtenidos tras optimización con Optuna para cada configuración.	52
4.3. Mejores resultados de detección de anomalías en el dataset IOPS. Se muestran las métricas de calidad para cada modelo evaluado.	52
4.4. Resultados de detección de anomalías en dataset Callt2. N representa el número de neuronas en las capas B y C para los modelos SNN. Se muestran los mejores resultados obtenidos tras optimización con Optuna para cada configuración.	53
4.5. Mejores resultados de detección de anomalías en el dataset Callt2. Se muestran las métricas de calidad para cada modelo evaluado.	53

5.1. Resumen del grado de cumplimiento de los objetivos planteados.	56
---	----

Siglas

ANN	<i>Artificial Neural Network</i> , Red Neuronal Artificial.
API	<i>Application Programming Interface</i> , Interfaz de Programación de Aplicaciones.
ASHA	<i>Asynchronous Successive Halving Algorithm</i> , Algoritmo Asíncrono de Reducción Sucesiva.
CNN	<i>Convolutional Neural Network</i> , Red Neuronal Convolutacional.
CNTS	<i>Cooperative Network Time Series</i> , Series Temporales de Red Cooperativa.
CPC	<i>Contrastive Predictive Coding</i> , Codificación Predictiva Contrastiva.
CPU	<i>Central Processing Unit</i> , Unidad Central de Procesamiento.
CUDA	<i>Compute Unified Device Architecture</i> , Arquitectura Unificada de Dispositivos de Cómputo.
CUSUM	<i>Cumulative Sum</i> , Suma Acumulada.
ECTS	<i>European Credit Transfer and Accumulation System</i> , Sistema Europeo de Transferencia y Acumulación de Créditos.
GPU	<i>Graphics Processing Unit</i> , Unidad de Procesamiento de Gráficos.
IOPS	<i>Input/Output Operations Per Second</i> , Operaciones de Entrada/Salida por Segundo.
IoT	<i>Internet of Things</i> , Internet de las Cosas.
JSON	<i>JavaScript Object Notation</i> , Notación de Objetos de JavaScript.
LIF	<i>Leaky Integrate-and-Fire</i> , Integración con Fuga y Disparo.

LSTM	<i>Long Short-Term Memory</i> , Memoria a Corto y Largo Plazo.
MAC	<i>Multiply-Accumulate</i> , Multiplicación y Acumulación.
ML	<i>Machine Learning</i> , Aprendizaje Máquina.
MSE	<i>Mean Squared Error</i> , Error Cuadrático Medio.
NAB	<i>Numenta Anomaly Benchmark</i> , Benchmark de Anomalías Numenta.
NoC	<i>Network on Chip</i> , Red en Chip.
RAM	<i>Random Access Memory</i> , Memoria de Acceso Aleatorio.
SNN	<i>Spiking Neural Network</i> , Red Neuronal de Impulsos.
SPC	<i>Statistical Process Control</i> , Control Estadístico de Procesos.
STDP	<i>Spike-Timing-Dependent Plasticity</i> , Plasticidad Dependiente del Tiempo de Impulsos.
STL	<i>Seasonal-Trend decomposition using Loess</i> , Descomposición Estacional-Tendencia usando Loess.
TFM	<i>Trabajo Fin de Máster</i> , Master's Thesis.
TPE	<i>Tree-structured Parzen Estimator</i> , Estimador de Parzen con Estructura de Árbol.
TSFEDL	<i>Time Series Feature Extraction Deep Learning</i> , Extracción de Características de Series Temporales mediante Aprendizaje Profundo.
UCR	<i>University of California, Riverside</i> , Universidad de California, Riverside.
VRAM	<i>Video Random Access Memory</i> , Memoria de Acceso Aleatorio de Vídeo.
WSL	<i>Windows Subsystem for Linux</i> , Subsistema de Windows para Linux.

Resumen

La detección de anomalías en series temporales es un problema transversal que afecta a múltiples sectores, desde la supervisión de redes hasta el mantenimiento predictivo de infraestructuras críticas. Los enfoques tradicionales resultan eficaces, pero presentan limitaciones en eficiencia energética y escalabilidad, especialmente en escenarios de dispositivos con recursos restringidos.

Este Trabajo Fin de Máster desarrolla y optimiza una arquitectura híbrida SNN-CNN para la detección de anomalías en series temporales, con énfasis en sostenibilidad computacional y eficiencia energética. Las SNN resultan especialmente prometedoras al aproximar la dinámica del cerebro y favorecer, por su activación esporádica, un consumo energético potencialmente inferior.

La propuesta parte de una SNN base (A-B) y añade una capa convolucional optimizable (A-B-C) con núcleos parametrizables (gaussiano, laplaciano, sombrero mexicano, caja) y distintos modos de procesamiento (directo, suma ponderada, máximo). El objetivo es combinar la extracción espacial propia de las redes convolucionales con la eficiencia temporal asíncrona de las SNN.

Para la búsqueda de hiperparámetros se emplea optimización bayesiana con Optuna TPE, ejecutando 100 pruebas por configuración en tres tamaños de red (100, 200 y 400 neuronas). El flujo de preprocesamiento, plenamente reproducible, incluye cuantización dinámica por cuantiles expandidos, expansión de etiquetas para mitigar el desequilibrio temporal y segmentación en ventanas de longitud $T=250$.

El análisis de resultados obtenidos confirma que los parámetros neuronales (threshold, decay) y de plasticidad (nu1, nu2) son los más influyentes. Los parámetros convolucionales (kernel_size, sigma) se sitúan a continuación, lo que refuerza que la dinámica LIF desempeña un papel clave en el rendimiento del modelo.

Las principales contribuciones son: (1) una arquitectura híbrida SNN-CNN optimizable de forma automática; (2) un flujo de preprocesamiento reproducible adaptado a las SNN; (3) evidencia empírica de que la hibridación mejora de forma

notable el rendimiento en conjuntos de datos desequilibrados; y (4) una metodología comparativa que puede servir de base para trabajos posteriores en el área.

En conjunto, el trabajo demuestra el potencial de las arquitecturas híbridas SNN-CNN para la detección de anomalías, al ofrecer un buen equilibrio entre rendimiento y eficiencia computacional, lo que las posiciona como una alternativa viable para aplicaciones de tiempo real en entornos con restricciones energéticas.

Abstract

Anomaly detection in time series is a cross-cutting problem affecting multiple sectors, from network monitoring to predictive maintenance of critical infrastructures. Traditional approaches are effective but present limitations in energy efficiency and scalability, especially in scenarios with resource-constrained devices.

This Master's Thesis develops and optimizes a hybrid SNN-CNN architecture for time series anomaly detection, with emphasis on computational sustainability and energy efficiency. SNNs are particularly promising as they approximate brain dynamics and favor, through their sparse activation, potentially lower energy consumption.

The proposal starts from a base SNN (A–B) and adds an optimizable convolutional layer (A–B–C) with parametrizable kernels (Gaussian, Laplacian, Mexican hat, box) and different processing modes (direct, weighted sum, maximum). The goal is to combine the spatial extraction characteristic of convolutional networks with the asynchronous temporal efficiency of SNNs.

For hyperparameter search, Bayesian optimization with Optuna TPE is employed, executing 100 trials per configuration across three network sizes (100, 200, and 400 neurons). The fully reproducible preprocessing workflow includes dynamic quantization by expanded quantiles, label expansion to mitigate temporal imbalance, and segmentation into windows of length $T=250$.

Analysis of obtained results confirms that neural parameters (threshold, decay) and plasticity parameters (ν_1 , ν_2) are the most influential. Convolutional parameters (kernel_size, sigma) follow, which reinforces that LIF dynamics play a key role in model performance.

The main contributions are: (1) an automatically optimizable hybrid SNN-CNN architecture; (2) a reproducible preprocessing workflow adapted to SNNs; (3) empirical evidence that hybridization notably improves performance on imbalanced datasets; and (4) a comparative methodology that can serve as a foundation for subsequent work in the area.

Overall, this work demonstrates the potential of hybrid SNN-CNN architectures for anomaly detection, offering a favorable balance between performance and computational efficiency, which positions them as a viable alternative for real-time applications in energy-constrained environments.

Capítulo 1

Introducción

1.1. Motivación

En el mundo actual, donde los datos crecen de forma exponencial, detectar comportamientos anómalos en series temporales se ha vuelto algo crítico para muchos sectores. Ya sea en la monitorización de redes informáticas o en el control de sistemas industriales, identificar patrones irregulares a tiempo puede prevenir fallos, optimizar recursos y garantizar la seguridad de infraestructuras críticas.

Las anomalías en series temporales son desviaciones significativas de lo que consideraríamos comportamiento normal o esperado en un sistema. Pueden aparecer como picos inusuales, cambios bruscos en la tendencia, o alteraciones en cómo se repiten los datos periódicamente. Detectar estas irregularidades de forma efectiva es complicado, sobre todo cuando trabajamos con sistemas complejos que generan grandes cantidades de datos en tiempo real.

Durante las últimas décadas se han desarrollado varios métodos para abordar este problema, desde técnicas estadísticas tradicionales hasta algoritmos complejos de aprendizaje automático. Más recientemente, los modelos de aprendizaje profundo como autoencoders y redes neuronales recurrentes han demostrado un buen rendimiento en este campo, gracias a que pueden capturar relaciones no lineales y patrones temporales en los datos [3, 4]. Pero estos modelos convencionales tienen sus limitaciones, especialmente en cuanto a eficiencia computacional y consumo energético—algo crítico en dispositivos con recursos limitados o cuando necesitas procesamiento en tiempo real [4, 5].

Las SNNs aparecen como un enfoque interesante que intenta imitar mejor

cómo funciona el cerebro biológico. Ofrecen ventajas en eficiencia energética y procesamiento temporal inherente comparado con los modelos convencionales de deep learning [6, 7, 8]. Este trabajo se enmarca en la línea de investigación que abrieron estudios pioneros que demostraron que las SNNs pueden funcionar para detección de anomalías mediante mecanismos de inhibición sináptica y codificación temporal [3, 7, 8]. Se proponen mejoras arquitecturales y de optimización que superan limitaciones identificadas en implementaciones previas.

1.2. Objetivos

El objetivo general del proyecto es el desarrollo y optimización de sistemas de detección de anomalías basados en SNNs. Para alcanzar dicho objetivo, resulta necesario abordar un conjunto de subobjetivos específicos listados a continuación:

1. Revisión bibliográfica de modelos de SNNs y su aplicación en detección de anomalías y mantenimiento predictivo.
2. Diseño y desarrollo de arquitecturas de SNNs optimizadas para la detección de anomalías en datos de sensores industriales.
3. Implementación de modelos de SNNs sostenibles que minimicen el consumo energético sin sacrificar la precisión.
4. Validación de los modelos desarrollados mediante experimentación en conjuntos de datos reales de mantenimiento predictivo.
5. Comparación de la eficiencia energética y el rendimiento predictivo frente a modelos tradicionales de detección de anomalías.

1.3. Estructura de la memoria

A continuación se describe la estructura de esta memoria. Consta de 5 capítulos:

- **Capítulo 1:** Este primer capítulo presenta la motivación del proyecto, explicando por qué es tan importante detectar anomalías en series temporales para distintos sectores industriales. Se establecen los objetivos específicos: diseñar arquitecturas SNNs optimizadas e implementar modelos sostenibles que

reduzcan el consumo energético. También se incluye la planificación temporal del proyecto con estimaciones de costes y duración de las tareas principales.

- **Capítulo 2:** Este capítulo presenta un análisis de la evolución histórica de los métodos de detección de anomalías, desde técnicas estadísticas clásicas hasta los enfoques más recientes de aprendizaje profundo. Se examinan los fundamentos estadísticos y enfoques tradicionales, las aplicaciones del aprendizaje profundo en detección de anomalías, y la optimización de hiperparámetros mediante técnicas bayesianas. Se dedica especial atención a las SNNs, la arquitectura del modelo base en que hace de punto de partida para este trabajo, y la comparación de eficiencia energética entre diferentes paradigmas computacionales.
- **Capítulo 3:** En este capítulo se define el alcance específico del proyecto, las hipótesis de partida y las restricciones identificadas. Se describe en detalle la solución propuesta, incluyendo la justificación para usar BindsNET como framework de desarrollo y los desafíos técnicos encontrados durante la configuración del entorno. El capítulo profundiza en la arquitectura del nuevo modelo híbrido SNN-CNN, explicando las innovaciones introducidas respecto a la implementación original, incluyendo la capa convolucional parametrizable y los modos de procesamiento. También describe los algoritmos de preprocesamiento desarrollados para los datasets IOPS y Callt2, incluyendo normalización temporal, completado de datos y técnicas de expansión de etiquetas.
- **Capítulo 4:** Este capítulo presenta la evaluación experimental del modelo propuesto. Se describen los escenarios experimentales implementados, incluyendo la configuración de hardware y software, los datasets utilizados y las estrategias de particionado temporal. Se detalla la metodología de evaluación, con especial énfasis en las métricas de calidad (precisión, recall, F1-score) y MSE. El análisis de resultados incluye comparaciones detalladas entre el modelo SNN base, el modelo híbrido propuesto y baselines de la librería TSFEDL [9], así como evaluaciones de escalabilidad con diferentes configuraciones de neuronas (100, 200, 400).
- **Capítulo 5:** El último capítulo sintetiza los principales hallazgos del trabajo, evaluando el grado de cumplimiento de los objetivos planteados y el impacto de las contribuciones realizadas. Se presenta una discusión de resultados con interpretación técnica e implicaciones prácticas, se discuten las limitaciones identificadas durante el desarrollo y se proponen direcciones para trabajos

futuros que puedan extender y mejorar los métodos desarrollados, con especial atención a la evaluación energética en hardware neuromórfico.

1.4. Planificación temporal

La asignación temporal de las tareas que componen este proyecto se puede ver en la Figura 1.1. Esta planificación es orientativa y puede sufrir retrasos o modificaciones según avanza el proyecto. Para estimar los costes, se ha considerado una dedicación de 25 horas semanales, con un coste de 22.80€ por hora [10].

1.4.1. Estimación temporal

Tarea	Duración (semanas)	Coste
Revisión bibliográfica	3	1.710,00€
Implementación de modelo híbrido SNN-CNN	4	2.280,00€
Configuración de Framework BindsNET	0,5	285,00€
Optimización de hiperparámetros con Optuna	1,5	855,00€
Selección y preprocesamiento de datos	2	1.140,00€
Experimentación y validación	3	1.710,00€
Análisis comparativo de resultados	2	1.140,00€
Documentación	2	1.140,00€
TOTAL	18	10.260,00€

Tabla 1.1: Planificación temporal de tareas, con duración estimada en semanas y coste asociado.

Inicialmente se realizará una revisión bibliográfica exhaustiva sobre las SNNs, especialmente su aplicación en detección de anomalías y mantenimiento predictivo. Este análisis permitirá identificar y seleccionar los enfoques y modelos más recientes y relevantes del campo, así como determinar los mejores métodos de optimización multiobjetivo y evaluación comparativa de eficiencia energética entre SNNs y modelos tradicionales.

A continuación, se implementará el modelo híbrido SNN-CNN, añadiendo mejoras como la capa convolucional adaptable y la optimización de hiperparámetros mediante frameworks como Optuna. Se prestará especial atención a la integración y configuración del entorno de trabajo con BindsNET.

En paralelo se procederá a explorar y seleccionar las fuentes de datos, poniendo especial énfasis en la disponibilidad y calidad de conjuntos como IOPS y Callt2, que necesitan flujos de preprocesamiento específicos para codificar bien los datos temporales y tratar valores faltantes. Esta etapa es crucial para asegurar que los datos sean adecuados para entrenar y validar bien los modelos de detección de anomalías.

Una vez validada la arquitectura y el procesamiento de datos, se lanzará la fase de experimentación, implementando escenarios controlados y métricas de evaluación que permitan comparar objetivamente el rendimiento y la eficiencia energética frente a modelos tradicionales. Los resultados se analizarán en profundidad, documentando las mejoras arquitecturales y trade-offs identificados, y generando visualizaciones comparativas.




Figura 1.1: Diagrama de Gantt del proyecto. Fuente: Elaboración propia.

Capítulo 2

Fundamentos Teóricos y Estado del Arte

2.1. Evolución temporal de métodos de detección de anomalías en series temporales

En este capítulo se presenta un análisis integral de la progresión histórica de las metodologías de detección de anomalías en series temporales, abarcando casi un siglo de avance tecnológico desde el control estadístico de procesos fundamental hasta las SNNs. La evolución revela paradigmas tecnológicos distintos que han dado forma al campo, cada uno abordando limitaciones específicas mientras introduce nuevas capacidades en términos de eficiencia computacional, precisión de detección y aplicabilidad en el mundo real. A través del examen sistemático de innovaciones, este estudio identifica hitos tecnológicos clave y proporciona una verificación crítica de los marcos cronológicos existentes. El análisis demuestra cómo las compensaciones entre eficiencia energética y precisión han impulsado transiciones metodológicas, al tiempo que destaca enfoques híbridos emergentes que combinan los beneficios de múltiples paradigmas para mejorar el rendimiento en la detección de anomalías.

2.2. Fundamentos estadísticos y enfoques clásicos

2.2.1. Métodos Iniciales de Control Estadístico de Procesos

El origen de la detección sistemática de anomalías en series temporales se remonta al trabajo pionero de Walter Shewhart en 1924, quien introdujo los gráficos de SPC [11]. Estos gráficos proporcionaron el primer marco formal para distinguir entre variación común y variación especial en procesos industriales, cambiando fundamentalmente cómo las organizaciones abordan la supervisión de la calidad y la identificación de anomalías. El enfoque de Shewhart enfatizó la importancia de comprender la variación natural del proceso antes de intentar identificar verdaderas anomalías, un principio que sigue siendo central en los sistemas modernos de detección de anomalías.

La evolución de los métodos de control estadístico continuó con la introducción del gráfico CUSUM por Page en 1954, un avance significativo en la sensibilidad para detectar pequeños cambios en el comportamiento de los procesos [12]. Los gráficos CUSUM acumulan información de observaciones anteriores, demostrando ser superiores a los gráficos Shewhart tradicionales para detectar desviaciones graduales [13, 14]. Este enfoque acumulativo resultó particularmente valioso para escenarios donde las anomalías se manifiestan como desviaciones sutiles y persistentes en lugar de picos dramáticos, haciendo de CUSUM una herramienta esencial para los sistemas ciberfísicos modernos y aplicaciones de seguridad.

2.2.2. Técnicas avanzadas de descomposición estadística

En 1967, MacQueen propone un método llamado agrupamiento K-means. Este enfoque basado en agrupamiento para la detección de anomalías representa un hito importante en los métodos no supervisados, donde las anomalías se identifican como puntos que no pertenecen a ningún grupo bien definido o forman grupos muy pequeños y aislados [15].

La década de 1990 marcó un avance significativo con el desarrollo del procedimiento STL, que permitió separar series temporales en componentes de tendencia, estacionalidad y residuos, facilitando la detección de anomalías con mayor precisión al modelar patrones esperados e identificar sus desviaciones [16]. El método demostró ser particularmente efectivo para aplicaciones de vigilancia en salud, donde modeló con éxito recuentos diarios de quejas principales descomponiéndolos

en componentes interanuales, estacionales anuales, día de la semana y errores aleatorios [17].

2.3. Aprendizaje profundo en la detección de anomalías

2.3.1. Fundamentos de redes neuronales y métodos basados en reconstrucción

La revolución del aprendizaje profundo transformó la capacidad de detectar anomalías mediante arquitecturas neuronales capaces de aprender patrones temporales complejos. Los autoencoders profundos surgieron como paradigma dominante alrededor de 2006, utilizando el error de reconstrucción como principio fundamental para identificar anomalías. Estas redes aprenden a comprimir patrones normales en representaciones de menor dimensión y luego los reconstruyen, con el supuesto de que los patrones anómalos exhibirán mayores errores de reconstrucción debido a su desviación de los comportamientos normales aprendidos [18].

Las LSTM fueron propuestas en 1997, en aquel momento existían limitaciones críticas en el modelado temporal al proporcionar mecanismos para capturar tanto dependencias a corto como a largo plazo en datos de series temporales [19]. Las implementaciones modernas a partir del 2010 a menudo integran redes LSTM con mecanismos de atención multi-cabeza y capas de red completamente conectadas para mejorar la precisión de predicción y las capacidades de detección de anomalías. Estas arquitecturas híbridas han demostrado ser particularmente efectivas en el análisis de transacciones blockchain, donde modelan con éxito la naturaleza dinámica, no lineal y variable en el tiempo de los patrones de transacción [20].

2.3.2. Arquitecturas avanzadas de aprendizaje profundo

El desarrollo de los VAEs alrededor de 2014 introdujo enfoques probabilísticos en la detección de anomalías, permitiendo la cuantificación de la incertidumbre y un manejo más robusto de distribuciones de datos complejas [21]. Trabajos recientes han demostrado la efectividad de las perspectivas variacionales espacio-temporales jerárquicas en la detección de anomalías en series temporales multivariadas,

modelando explícitamente variables estocásticas temporales y variables de relación de gráficos latentes dentro de marcos gráficos unificados [22, 23].

En 2018, ganan prominencia los enfoques de aprendizaje autosupervisado, particularmente a través de la aplicación de técnicas de CPC. En este estudio se busca transformar la identificación de anomalías en problemas de identificación de pares positivos [24]. El esquema CPC de salto de paso representa un avance notable, ajustando la distancia entre ventanas de historial y puntos de detección para mejorar la construcción de pares positivos y el rendimiento de detección [25].

2.4. Redes Neuronales de Impulsos

2.4.1. ¿Qué es una Red Neuronal de Impulsos?

Las redes neuronales que conocemos, las ANNs tradicionales, procesan información usando números continuos. Cada neurona recibe valores como 0.87 o 0.34, los procesa, y produce otro número continuo. Pero así no es como trabaja el cerebro real.

Las SNNs funcionan de manera diferente. En lugar de transmitir valores numéricos continuos, estas redes se comunican mediante impulsos breves de actividad eléctrica, igual que las neuronas biológicas. Un impulso es un evento discreto: la neurona dispara o no dispara.

Pensemos en una analogía: una ANN tradicional se parece a un termostato analógico que ajusta gradualmente la temperatura en un rango continuo de valores. Una SNN, en cambio, funciona más como un sistema de código Morse: transmite información mediante impulsos discretos que ocurren en momentos específicos del tiempo. El mensaje no está solo en si hay impulso o no, sino también en cuándo ocurre.

Diferencias fundamentales con las ANNs tradicionales

La tabla 2.1 resume las diferencias principales entre ambos paradigmas:

Aspecto	ANN Tradicional	SNN
Comunicación entre neuronas	Valores continuos (0.0 - 1.0)	Impulsos discretos (impulso/no impulso)
Información temporal	El momento exacto no importa	El TIEMPO del impulso es información
Activación	Cada neurona procesa en cada paso	Solo procesa cuando recibe un impulso
Operaciones	Multiplicaciones intensivas	Sumas y comparaciones

Tabla 2.1: Comparación entre ANNs tradicionales y SNNs

2.4.2. Componentes básicos de una SNN

Ahora que entendemos el concepto general, veamos las piezas que conforman una SNN y cómo funcionan.

La neurona de impulsos: modelo LIF

El tipo de neurona más común en SNNs se llama LIF. A continuación se explican los componentes clave de este modelo:

- **Fuga:** El voltaje no se mantiene indefinidamente. Si la neurona no recibe más entradas, el voltaje decae gradualmente con el tiempo, como si hubiera una fuga de carga.
- **Integración:** La neurona acumula las señales eléctricas que recibe. Cada vez que llega un impulso desde otra neurona, el voltaje de membrana aumenta.
- **Disparo:** Cuando el voltaje acumulado supera un umbral determinado, la neurona emite su propio impulso y su voltaje se reinicia a un valor de reposo.

En la literatura, la dinámica del modelo LIF se describe normalmente mediante una ecuación diferencial continua [26, 27]:

$$C_m \frac{dV(t)}{dt} = -g_L(V(t) - E_L) + I_{\text{syn}}(t) \quad (2.1)$$

donde C_m es la capacitancia de membrana, g_L la conductancia de fuga, E_L el voltaje de reposo, e $I_{\text{syn}}(t)$ la corriente sináptica de entrada.

Para simplificar las simulaciones, es habitual usar una versión discreta del modelo, que aproxima la ecuación anterior en pasos temporales:

$$V(t+1) = V(t) + \alpha(V_{\text{rest}} - V(t)) + I_{\text{entrada}}(t) \quad (2.2)$$

Si $V(t+1) \geq V_{\text{threshold}}$, la neurona dispara un impulso y se reinicia a V_{rest} .

Los parámetros principales son:

- $V(t)$: voltaje de la membrana en el instante t (unidad de medida: milivoltios, mV)
- α : factor de fuga, donde $0 < \alpha < 1$. α controla la rapidez con que el voltaje tiende hacia el reposo (por ejemplo, 0.2 indica que el voltaje recupera un 20 % de la diferencia hacia el reposo por paso temporal)
- V_{rest} : voltaje de reposo (por ejemplo, -65 mV)
- $V_{\text{threshold}}$: umbral de disparo (por ejemplo, -50 mV)
- $I_{\text{entrada}}(t)$: representa el efecto total de los impulsos recibidos en el instante t .

Ejemplo ilustrativo. Supongamos una neurona LIF con los siguientes parámetros:

- $V_{\text{rest}} = -65$ mV
- $V_{\text{threshold}} = -50$ mV
- $\alpha = 0,2$

En $t = 0$, la neurona está en reposo: $V(0) = -65$ mV. En $t = 1$, recibe un impulso de $+20$ mV. El término de fuga es:

$$\alpha = 0,2 \times (-65 - (-65)) = 0$$

$$V(1) = -65 + 0 + 20 = -45 \text{ mV}$$

El voltaje supera el umbral (-50 mV), por lo que la neurona dispara un impulso y se reinicia: $V(1) \rightarrow -65$ mV.

Si en $t = 2$ recibe un impulso de $+10$ mV:

$$\alpha = 0,2 \times (-65 - (-65)) = 0$$

$$V(2) = -65 + 0 + 10 = -55 \text{ mV}$$

El voltaje no alcanza el umbral. En $t = 3$, sin nuevas entradas, el voltaje decae:

$$\alpha = 0,2 \times (-65 - (-55)) = -2 \text{ mV}$$

$$V(3) = -55 + (-2) + 0 = -57 \text{ mV}$$

En $t = 4$, recibe un nuevo impulso de $+10 \text{ mV}$:

$$\alpha = 0,2 \times (-65 - (-57)) = -1,6 \text{ mV}$$

$$V(4) = -57 + (-1,6) + 10 = -48,6 \text{ mV}$$

Como $V(4) > -50 \text{ mV}$, la neurona dispara y se reinicia a $V_{\text{rest}} = -65 \text{ mV}$.

El proceso se repite en cada paso temporal, dando lugar a un patrón de disparos como el que se muestra en la Figura 2.1:

La simplicidad del modelo LIF es una de sus mayores ventajas: permite capturar la dinámica esencial del disparo neuronal sin recurrir a ecuaciones diferenciales complejas, lo que lo hace ideal para simulaciones eficientes.

Sinapsis: las conexiones entre neuronas

Cuando una neurona dispara un impulso, este no llega automáticamente a todas las demás neuronas. Viaja a través de sinapsis, las conexiones entre neuronas. Cada sinapsis tiene un peso sináptico que determina cuánto impacto tiene el impulso en la neurona receptora.

Los pesos pueden ser de dos tipos:

- **Positivos (excitatorios):** Aumentan el voltaje de la neurona receptora, haciéndola más propensa a disparar.
- **Negativos (inhibitorios):** Disminuyen el voltaje, haciendo menos probable que dispare.

Veamos un ejemplo concreto. Supón que la neurona A dispara un impulso y está




Figura 2.1: Ejemplo ilustrativo de una neurona LIF. Fuente: Elaboración propia.

conectada a la neurona B mediante una sinapsis con peso $+0,5$. Cuando el impulso llega, la neurona B recibe un incremento de voltaje de $+0,5$ mV. Si esa misma sinapsis tuviera un peso de $-0,3$, la neurona B experimentaría una disminución de $-0,3$ mV en su voltaje.

Esta interacción entre excitación e inhibición es fundamental. Las neuronas excitatorias activan a otras neuronas, propagando información. Las neuronas inhibitorias, en cambio, actúan como frenos, evitando que la red se sature con actividad descontrolada. El balance entre ambas determina la estabilidad y el comportamiento de la red.

2.5. Eficiencia energética

2.5.1. Limitaciones energéticas de los métodos tradicionales

Los métodos convencionales de detección de anomalías enfrentan desafíos significativos en términos de consumo energético, especialmente cuando se implementan en dispositivos con recursos limitados [28]. Las redes neuronales artificiales tradicionales requieren operaciones de multiplicación intensivas que consumen considerable energía, mientras que los métodos estadísticos, aunque menos demandantes computacionalmente, carecen de la capacidad para capturar patrones complejos no lineales [29, 2].

Comparaciones empíricas de ANN como autoencoders vs Técnicas estadísticas como Z-score muestran los siguientes resultados:

Método	Rendimiento		
	Precision	Recall	F1-score
Z-Score (método estadístico)	1.00	0.60	0.75
Autoencoders (ANN)	0.94	1.00	0.97

Tabla 2.2: Comparación de rendimiento entre métodos estadísticos y redes neuronales artificiales. Fuente: [2]

Para el método basado en Z-score, se reporta una precisión de 1.00, lo que indica que todas las anomalías identificadas fueron correctas, mientras que el recall es de 0.60, lo que sugiere que se detectó el 60 % de las anomalías reales. El F1-score, que equilibra precisión y recall, es de 0.75, reflejando la efectividad general de este método.

En contraste, el método con autoencoders logra una precisión de 0.94, lo que indica una alta proporción de anomalías correctamente identificadas con un mínimo de falsos positivos. El recall es de 1.00, indicando que se detectaron todas las anomalías reales. En consecuencia, el F1-score del método con autoencoders es de 0.97, lo que evidencia un rendimiento superior en comparación con el enfoque basado en Z-score. La mayor desventaja de este enfoque es su mayor consumo energético. Esta compensación entre precisión y eficiencia energética representa uno de los principales motivadores para la exploración de paradigmas computacionales alternativos [2].

2.5.2. Paradigma de eficiencia energética en SNNs

Las SNNs emergen como una solución prometedora debido a su naturaleza impulsada por eventos y su capacidad para realizar computación usando únicamente operaciones de acumulación en lugar de multiplicaciones costosas [30]. Esta característica fundamental permite que las SNNs consumen significativamente menos energía que sus contrapartes tradicionales.

Los sistemas de detección de anomalías basados en SNNs para redes IoT han logrado eficiencias energéticas aproximadamente 3.5 veces superiores a los modelos CNN tradicionales, con latencias de detección significativamente menores (hasta 3 veces más rápidas) [31]. Estos resultados demuestran que, aunque puede existir una ligera reducción en la precisión de detección de anomalías (89.3 % para SNN vs 92.5 % para CNN), los beneficios en eficiencia energética y latencia proporcionan un caso convincente para el uso de SNNs en aplicaciones específicas [31].

Un estudio reciente presenta una metodología de transformar exitosamente arquitecturas ANNs en SNNs con una penalización de error promedio marginal de tan solo 2,65 %. El algoritmo de particionamiento de grafos propuesto permite una disminución del 14,22 % en la comunicación intersináptica y una reducción del 87,58 % en la comunicación intrasináptica, en promedio, lo que subraya la efectividad del algoritmo propuesto en la optimización de las vías de comunicación de las redes neuronales. En comparación con un algoritmo de particionamiento de grafos de referencia, el enfoque propuesto muestra una disminución promedio del 79,74 % en la latencia y una reducción del 14,67 % en el consumo energético. Usando herramientas existentes de NoC, el producto energía-latencia de las arquitecturas SNN es, en promedio, un 82,71 % inferior al de las arquitecturas de referencia [32].

2.5.3. Hiperparámetros en SNN

La optimización de hiperparámetros SNNs representa un avance significativo en el desarrollo de sistemas de detección de anomalías eficientes energéticamente. Tradicionalmente, Búsqueda en Cuadrícula y Random Search se han usado como metodología de optimización de parámetros, donde la búsqueda en cuadrícula prueba cada combinación de hiperparámetros posibles y la búsqueda aleatoria genera grupos de parámetros dentro de los límites. Ambos métodos, aunque ampliamente utilizados, tienen sus limitaciones: a menudo son lentos y no siempre encuentran la combinación óptima de manera eficiente [33].

Actualmente existen frameworks especializados en optimizar la hiperparametrización como es el caso de Optuna. Este utiliza algoritmos de optimización bayesiana basados en TPE que permiten una exploración inteligente del espacio de hiperparámetros, enfocándose en regiones prometedoras en lugar de realizar búsquedas exhaustivas [34]. Esta aproximación resulta particularmente beneficiosa para SNNs, donde la sensibilidad a los hiperparámetros es especialmente crítica debido a la compleja dinámica temporal entre neuronas y impulsos, la optimización bayesiana puede descubrir configuraciones óptimas de hiperparámetros con significativamente menos evaluaciones que métodos tradicionales como la búsqueda en cuadrícula, reduciendo tanto el tiempo de experimentación como los recursos computacionales necesarios [35].

Optuna también cuenta con un mecanismo de poda basado en el algoritmo ASHA que permite detener automáticamente aquellos ensayos que no muestran resultados prometedores en las primeras etapas del entrenamiento [36]. Para SNNs, esto es especialmente valioso dado que pueden sufrir del problema conocido como "redes silenciosas", configuraciones que fallan en generar suficientes impulsos debido a hiperparámetros mal ajustados. La detección temprana de estas configuraciones no viables permite dirigir la búsqueda hacia combinaciones de hiperparámetros más prometedoras, evitando computaciones costosas e innecesarias que son particularmente relevantes en el contexto de optimización energética [35].

Los resultados experimentales demuestran que las SNNs optimizadas con Optuna pueden cerrar la brecha de precisión con respecto a las ANNs tradicionales mientras mantienen sus ventajas inherentes de eficiencia energética [37]. Esta optimización multiobjetivo resulta especialmente relevante para aplicaciones de edge computing y IoT, donde las restricciones energéticas son significativas y la detección temprana de anomalías es crítica para la seguridad y operación de sistemas industriales.

2.6. Arquitectura SNN base para detección de anomalías en series temporales

Una vez comprendidos los fundamentos de las SNNs, en esta sección se describe la arquitectura SNN base, específicamente diseñada para la detección de anomalías en series temporales, que constituye el punto de partida para la solución propuesta en el [Capítulo 3](#).

2.6.1. Arquitectura bicapa

El modelo SNN base consta de dos capas principales, denominadas A y B:

Capa A (entrada). Esta capa actúa como interfaz entre los datos de entrada y la red neuronal. Su función es transformar los valores continuos de la serie temporal en impulsos discretos. El número de neuronas en esta capa es 39.

Capa B (procesamiento). Compuesta por 100 neuronas LIF completamente conectadas a la capa A. Esta capa presenta dos características distintivas:

- Conexiones propagación hacia adelante desde la capa A: cada neurona de la capa B recibe entradas ponderadas desde todas las neuronas de la capa A.
- Conexiones recurrentes dentro de la propia capa B: las neuronas están interconectadas entre sí, permitiendo que los impulsos generados en esta capa influyan en el estado de las demás neuronas del mismo nivel. Estas conexiones recurrentes son fundamentales para capturar dependencias temporales en los datos.

2.6.2. Codificación por cuantiles

Para convertir valores continuos de series temporales en impulsos discretos, se emplea una estrategia de codificación basada en cuantiles estadísticos. Este método divide el rango de valores observados en el conjunto de entrenamiento en intervalos disjuntos, donde cada intervalo corresponde a una neurona de la capa A.

El proceso funciona de la siguiente manera:

1. Durante la fase de preparación, se calculan los cuantiles de la distribución de valores en los datos de entrenamiento. Por ejemplo, si se eligen n cuantiles, se obtienen $n - 1$ neuronas en la capa A.
2. Cada valor de la serie temporal se asigna al intervalo que le corresponde según su magnitud.
3. La neurona asociada a dicho intervalo genera un impulso en el instante temporal actual.




Figura 2.2: Diagrama de la arquitectura bicapa de la SNN base. Inspirado en [1].

4. Este impulso se propaga a la capa B a través de las conexiones sinápticas.

Esta codificación presenta ventajas importantes: es determinista, computacionalmente eficiente y adapta automáticamente la representación a la distribución estadística de los datos específicos del problema. Además, valores fuera del rango original pueden ser manejados mediante intervalos adicionales en los extremos.

2.6.3. Aprendizaje mediante STDP modificado

El entrenamiento de la red se realiza mediante una variante de STDP diseñada específicamente para la tarea de detección de anomalías. A diferencia del STDP clásico, donde se refuerzan conexiones que conducen a disparos postsinápticos inmediatos, aquí se emplea una estrategia de penalización bidireccional.

El mecanismo funciona de la siguiente forma:

- Se penalizan las conexiones hacia neuronas que hayan emitido impulsos recientemente (impulsos presinápticos).
- También se penalizan las conexiones hacia neuronas que disparen inmediatamente después del impulso actual (impulsos postsinápticos).

Esta doble penalización tiene como objetivo inhibir la generación de impulsos cuando la red procesa datos normales, es decir, datos similares a los observados durante el entrenamiento. La intuición es que, si la red ha aprendido correctamente los patrones normales, debería generar pocos impulsos al encontrarlos nuevamente. En cambio, ante datos anómalos, las conexiones ajustadas no serán efectivas para suprimir la actividad, resultando en un mayor número de impulsos.

Los parámetros de aprendizaje ν_1 y ν_2 controlan la magnitud de los ajustes sinápticos en las conexiones $A \rightarrow B$ y $B \rightarrow B$ respectivamente. Estos valores son típicamente negativos para implementar la penalización descrita.

2.6.4. Criterio de detección de anomalías

Una vez entrenada la red, la detección de anomalías se basa en la frecuencia de impulsos generados por la capa B durante la inferencia. El procedimiento es el siguiente:

1. Durante el procesamiento de nuevos datos, se monitoriza la actividad de disparo de las neuronas en la capa B.
2. Se calcula una métrica agregada de la actividad neuronal, típicamente la suma de impulsos en una ventana temporal deslizante.
3. Esta señal de actividad se suaviza mediante técnicas como media móvil para reducir fluctuaciones instantáneas.
4. Se compara la actividad suavizada con un umbral estadístico predeterminado.
5. Cuando la actividad supera el umbral, se genera una alerta de anomalía.

El umbral puede establecerse mediante análisis estadístico de la actividad observada durante el procesamiento de datos de validación normales, por ejemplo, utilizando la media más dos desviaciones estándar.

2.6.5. Limitaciones de la arquitectura base

Aunque esta arquitectura demuestra la viabilidad de aplicar SNNs a la detección de anomalías, presenta varias limitaciones que motivan el desarrollo de mejoras:

- Ausencia de extracción de características jerárquicas: la conectividad completamente conectada (fully-connected) no captura eficientemente patrones locales o estructuras temporales específicas, que son fundamentales para detectar anomalías sutiles en series temporales complejas.
- Sensibilidad a hiperparámetros: los parámetros ν_1 , ν_2 , el umbral de disparo y la constante de decaimiento deben ajustarse manualmente o mediante búsqueda exhaustiva, sin un mecanismo de optimización automatizada.
- Rendimiento limitado en presencia de ruido: en conjuntos de datos con alta variabilidad o ruido temporal, la red puede generar falsos positivos al interpretar variaciones normales como comportamientos anómalos.
- Escalabilidad computacional: aunque las SNNs son intrínsecamente eficientes, la ausencia de capas especializadas para reducción de dimensionalidad puede limitar su aplicación a series temporales de gran longitud o alta frecuencia de muestreo.
- Criterio de alerta simple: la decisión de anomalía se basa únicamente en estadísticas agregadas de impulsos en la capa B, sin aprovechar potencialmente múltiples representaciones o rutas de procesamiento paralelo.

Estas limitaciones serán abordadas en el [Capítulo 3](#) mediante la introducción de una arquitectura híbrida que combina la eficiencia de las SNNs con capacidades de procesamiento convolucional, optimización automatizada de hiperparámetros y estrategias de decisión más sofisticadas.

2.7. Conclusiones

La evolución desde métodos estadísticos clásicos hasta redes neuronales de impulsos evidencia un patrón consistente: cada paradigma emergente busca superar las limitaciones anteriores mediante nuevos compromisos entre precisión y eficiencia computacional. Los métodos de aprendizaje profundo demuestran

capacidad superior en captura de patrones temporales complejos, pero con costes energéticos considerables; en contraste, las SNNs ofrecen mejoras de eficiencia energética de hasta 3.5 veces respecto a arquitecturas CNN, aunque con ligeras reducciones en precisión.

La arquitectura SNN base bicapa, fundamentada en neuronas LIF y aprendizaje STDP modificado, demuestra viabilidad del enfoque pero expone limitaciones: ausencia de extracción de características jerárquicas y escalabilidad limitada. La optimización bayesiana con Optuna permite cerrar significativamente la brecha de precisión preservando las ventajas energéticas inherentes a las SNNs.

En conclusión, el desarrollo de sistemas eficientes de detección de anomalías requiere arquitecturas híbridas que combinen estratégicamente las fortalezas de múltiples enfoques, particularmente para aplicaciones que demanden simultáneamente alta precisión y eficiencia energética.

Capítulo 3

Especificación del trabajo

3.1. Alcance

Los entregables y resultados que se esperan obtener de este trabajo son:

- **Código fuente.**
- **Modelos utilizados.**
- **Resultados.**
- **Memoria.**

3.2. Hipótesis y Restricciones

3.2.1. Restricciones

Las limitaciones que se presentan para comprobar la hipótesis de partida anterior pueden ser intelectuales, temporales o económicas y se presentan las principales a continuación:

- **R1. La duración del proyecto:** Este proyecto debe regirse por el límite de tiempo que implican los 12 créditos ECTS de un TFM, lo que implica un límite de dedicación de aproximadamente 300 horas.

- **R2. Disponibilidad y calidad de datasets de mantenimiento predictivo:** La disponibilidad de conjuntos de datos reales y etiquetados para detección de anomalías en aplicaciones de mantenimiento predictivo es limitada. Los datasets públicos como IOPS y Callt2 utilizados en experiencias previas requieren preprocesamiento extensivo y pueden no representar completamente la diversidad de escenarios industriales reales.
- **R3. Limitaciones en la evaluación de eficiencia energética:** La validación experimental de las ventajas energéticas de las SNNs frente a métodos tradicionales requiere hardware especializado neuromórfico o mediciones precisas de consumo energético que no están disponibles en el entorno de desarrollo.
- **R4. Complejidad en la optimización de hiperparámetros:** Los sistemas SNN presentan una sensibilidad particular a los hiperparámetros debido a la compleja dinámica temporal entre neuronas y impulsos. La optimización de estos parámetros mediante frameworks como Optuna requiere tiempo computacional considerable y está limitada por los recursos disponibles y el tiempo del proyecto.

3.3. Descripción de la solución propuesta

Este trabajo propone el desarrollo y una serie de mejoras a un sistema de detección de anomalías en series temporales basado en SNNs, a continuación se enumeran dichas mejoras:

- Seleccionar Framework para el desarrollo de la mejora del modelo previo.
- Incorporar una arquitectura híbrida que combina las ventajas de las capas convolucionales con la eficiencia energética inherente de las SNNs. Esta arquitectura híbrida SNN-CNN busca aprovechar la capacidad de extracción de características espaciales de las redes convolucionales junto con el procesamiento temporal asíncrono y la eficiencia energética de las SNNs. Esta capa convolucional incluida, recibe las salidas de la Capa B y aplica un kernel para el filtrado convolucional de los impulsos.
- Incorporar Optuna para obtener la mejor configuración de cada modelo mediante la hiperparametrización.
- Desarrollar algoritmos de preprocesamiento de los datos.

- Evaluar comparando resultados con el modelo (sin la capa convolucional) y con modelos de la librería TSFEDL [9].

3.4. Selección de BindsNET como framework de desarrollo

La selección de BindsNET como framework de desarrollo se fundamentó en una evaluación comparativa de las opciones disponibles para la simulación de SNNs orientadas al aprendizaje automático [38]. BindsNET proporciona objetos y métodos de software que permiten la simulación de grupos de diferentes tipos de neuronas (`bindsnet.network.nodes`), así como de diferentes tipos de conexiones entre ellas (`bindsnet.network.topology`). Estos pueden combinarse en un único objeto `bindsnet.network.Network`, responsable de coordinar la lógica de simulación de todos los componentes subyacentes [39].

Las características técnicas que determinaron esta selección incluyen su integración nativa con PyTorch (herramienta con la que se cuenta experiencia previa), lo que facilita la implementación en plataformas computacionales de alto rendimiento tanto en CPU como GPU. Adicionalmente, BindsNET ofrece una sintaxis concisa y orientada al usuario que resulta particularmente adecuada para prototipado rápido, aspecto crucial durante las fases iniciales de desarrollo algorítmico [39].

Los detalles sobre la instalación y configuración del entorno de desarrollo, incluyendo la resolución de conflictos de dependencias y problemas de compatibilidad, se encuentran documentados en el Anexo A.

3.5. Arquitectura del nuevo modelo híbrido

3.5.1. Motivación y diferencias respecto al modelo SNN base

Como se describió en la Sección 2.6, el modelo SNN base para detección de anomalías consta de una arquitectura bicapa (A-B) donde la capa de entrada emplea codificación por cuantiles y la capa de procesamiento contiene neuronas LIF con conexiones recurrentes entrenadas mediante STDP modificado. Si bien esta arquitectura demuestra la viabilidad de aplicar SNNs a la detección de anomalías en series temporales, se identificaron varias limitaciones fundamentales que motivan el

desarrollo de un modelo mejorado.

La motivación principal para desarrollar este modelo híbrido surge directamente de las limitaciones expuestas en el [Capítulo 2](#). Específicamente, la ausencia de mecanismos de optimización automatizada de hiperparámetros y de procesamiento jerárquico puede conducir a un rendimiento subóptimo en escenarios con ruido o alta variabilidad.

El modelo híbrido propuesto aborda estas limitaciones mediante las siguientes innovaciones arquitecturales:

- **Procesamiento jerárquico:** Se integra una capa convolucional (C) después de la capa B, creando una arquitectura híbrida SNN-CNN. La capa C aplica convoluciones sobre los impulsos de B para capturar patrones locales utilizando kernels configurables (Gaussiano, Laplaciano, Mexican Hat, Box).
- **Optimización automatizada con Optuna:** Los hiperparámetros (nu1, nu2, umbral, decaimiento, parámetros de kernel) se optimizan automáticamente para maximizar métricas como F1-score, eliminando la necesidad de ajuste manual.
- **Rutas duales de procesamiento:** El sistema permite evaluar las salidas de las capas B y C en paralelo, seleccionando automáticamente la representación más informativa según criterios de MSE y métricas de clasificación.
- **Filtrado adaptativo de ruido:** Las convoluciones en la capa C actúan como filtros temporales que suavizan fluctuaciones espurias, mejorando la robustez en conjuntos de datos ruidosos.
- **Mejora en generalización:** Soporte para múltiples conjuntos de datos (IoPS, Callt2) con técnicas de expansión de etiquetas y padding para manejar secuencias de longitud variable.

En términos de implementación, las diferencias clave incluyen la adición de monitores específicos para la capa C, tres modos de procesamiento convolucional (direct, weighted_sum, max) que serán explicados en la [Sección 3.5.5](#), y evaluación dual de métricas tanto para la capa B como para la capa C. Esta arquitectura híbrida resulta en un modelo más flexible, manteniendo la eficiencia computacional inherente a las SNNs mientras incorpora las capacidades de extracción de características de las redes convolucionales.

3.5.2. Análisis de Variables Modificables del Modelo Híbrido

Tabla comparativa de cambios estructurales:

Estas tablas (3.1 y 3.2) resaltan cómo el modelo híbrido extiende la original sin alterar su núcleo, pero modificando donde es necesario para mejorar el rendimiento.

Aspecto	Modelo SNN Base (A–B)	Modelo Híbrido (A–B–C)
Tipo de capas	A: Input (codificación de cuantiles). B: Fully-connected LIF.	A: Input (codificación de cuantiles). B: Fully-connected LIF con conexiones recurrentes. C: AdaptiveLIF con kernels convolucionales configurables (Gaussian, Laplacian, Mexican Hat, Box).
Número Neuronas	A: Variable según cuantiles ($\text{len}(\text{cuantiles})-1$). B: 100 (fijo).	A: Variable según cuantiles ($\text{len}(\text{cuantiles})-1$). B: Configurable vía <code>snn_process_layer_neurons_size</code> (por defecto: 100). C: Igual tamaño que B ($n = \text{snn_process_layer_neurons_size}$).
Conexiones	A → B: Pesos aleatorios. B → B: Recurrentes con pesos negativos.	A → B: Pesos $0.3 + 0.2 \cdot \text{randn}$. B → B: Recurrentes $0.025 \cdot (\text{eye}-1)$. B → C: Convolucional con kernels optimizables.
Parámetros Optimizables	Parámetros fijos o manuales: <code>nu1</code> , <code>nu2</code> , <code>threshold</code> , <code>decay</code> .	Optimización vía Optuna: <code>nu1</code> , <code>nu2</code> ∈ [-0.5, 0.5]. <code>threshold</code> ∈ [-65, -50]. <code>decay</code> ∈ [80, 150]. <code>kernel_size</code> ∈ [3, 9] (impares). <code>sigma</code> ∈ [0.5, 3.0]. <code>norm_factor</code> ∈ [0.1, 1.0]. <code>exc_inh_balance</code> ∈ [-0.3, 0.3].
Procesamiento Convolucional	No disponible.	Tres modos: <code>direct</code> , <code>weighted_sum</code> , <code>max</code> . Kernels adaptativos con balance excitatorio-inhibitorio.

Tabla 3.1: Comparación entre modelo SNN base y modelo híbrido — Parte 1: arquitectura, conexiones y optimización.

Aspecto	Modelo SNN Base (A–B)	Modelo Híbrido (A–B–C)
Criterio de alerta	Basado en umbral estadístico en impulsos de B. Métricas: Precisión, Recall, F1.	Evaluación dual: Impulsos de B y C. Optimización: Maximiza $\max(F1_B, F1_C)$. Métricas: MSE, F1, Precisión, Recall para ambas capas.
Integración con MLOps	Sin integración automatizada.	Integración con Weights & Biases (wandb). Seguimiento de experimentos y métricas en tiempo real. Guardado automático de configuraciones óptimas.
Dispositivo de Cómputo	CPU únicamente.	Soporte para CPU/GPU configurable. Optimización automática según disponibilidad de hardware.
Limitaciones abordadas	Sensible a ruido; parámetros fijos; sin extracción de características locales.	Reducción de ruido vía convolución adaptativa. Optimización automática de hiperparámetros. Extracción de patrones temporales mejorada. Escalabilidad en hardware.

Tabla 3.2: Comparación entre modelo SNN base y modelo híbrido — Parte 2: evaluación, implementación y ventajas.

3.5.3. Variables Centrales del Modelo Híbrido

3.5.4. Parámetros de Optimización con Optuna

Parámetros de Aprendizaje STDP

- **nu1**: Controla la actualización sináptica en la conexión $A \rightarrow B$ (entrada a procesamiento).
- **nu2**: Regula el aprendizaje en conexiones $B \rightarrow B$ (recurrentes) y $B \rightarrow C$ (convolucionales).

Valores negativos fortalecen conexiones (excitación), valores positivos las debilitan (inhibición). El rango $[-0.5, 0.5]$ permite explorar desde inhibición fuerte hasta excitación moderada.

Parámetros Neuronales LIF

- **threshold**: Umbral de disparo de las neuronas LIF/AdaptiveLIF. Umbrales más altos (-50 mV) requieren mayor activación para disparar, creando mayor selectividad.
- **decay**: Constante de tiempo de decaimiento de la membrana neuronal. Decaimientos altos (150) mantienen la información por más tiempo.

Configuración de Parámetros Convolucionales del Kernel

- **kernel_type**: Define la forma del filtro convolucional.
 - Gaussian**: Suavizado gradual, ideal para reducir ruido temporal.
 - Laplacian**: Detección de bordes/cambios abruptos.
 - Mexican Hat**: Detección de características con supresión lateral.
 - Box**: Promediado simple, computacionalmente eficiente.
- **kernel_size**: Tamaño de la ventana temporal del filtro (solo valores impares). Valores pequeños (3): Capturan cambios rápidos, mayor sensibilidad. Valores grandes (9): Suavizado temporal extenso, menor sensibilidad al ruido.

- **sigma**: Anchura del filtro gaussiano. Valores bajos (0.5): Kernels más puntiagudos, filtrado local. Valores altos (3.0): Kernels más anchos, filtrado global.

Balance Excitatorio-Inhibitorio

- **norm_factor**: Factor de normalización de pesos convolucionales. Controla la intensidad global de las conexiones B→C. Valores altos (1.0) aumentan la influencia de la capa convolucional.
- **exc_inh_balance**: Balance entre conexiones excitatorias/inhibitorias. Implementado mediante máscara aleatoria en la matriz de pesos. Valores negativos (-0.3): Predominan conexiones inhibitorias. Valores positivos (0.3): Predominan conexiones excitatorias.

3.5.5. Modos de Procesamiento Convolucional

- **direct**: Usa directamente los impulsos de la capa C
- **weighted_sum**: $\text{conv_spikes} = 0.3 * \text{b_spikes_sum} + 0.7 * \text{c_spikes_sum}$
Combinación ponderada de capas B y C. Mayor peso (0.7) a la capa convolucional, aprovechando el filtrado.
- **max**: Elemento máximo entre ambas capas. Preserva la activación más fuerte.

3.5.6. Esquema general

A continuación se presenta el esquema global de la arquitectura híbrida SNN–CNN, integrando tres dominios diferenciados: codificación y preprocesado, arquitectura SNN (capas A,B) y bloque convolucional híbrido (capa C). El diagrama muestra cómo fluye la información desde la señal de entrada hasta la inferencia final, destacando las rutas paralelas de procesamiento y los puntos de monitorización clave.

En el primer dominio, la señal de serie temporal es previamente procesada y codificada en impulsos a través de cuantización y agrupamiento temporal. Este bloque prepara los trenes de impulsos que alimentan el núcleo SNN. A continuación, en el segundo dominio, la capa A recibe estos impulsos y los transmite a la capa B, donde se aplica dinámica recurrente LIF con aprendizaje STDP. La salida de B se bifurca: una

ruta va directamente a la fase de inferencia sobre impulsos de B, y la otra alimenta el bloque convolucional.

El tercer dominio corresponde a la capa C, que aplica convoluciones 1D sobre los impulsos de la capa B utilizando kernels configurables (Gaussianos, Laplacianos, etc.). Esta capa aporta filtrado adaptativo y extracción de características locales antes de enviar su salida al mecanismo de decisión dual. Finalmente, el sistema evalúa ambas rutas (B y C) según métricas de clasificación y MSE, seleccionando automáticamente la representación más informativa.




Figura 3.1: Flujo de datos y arquitectura SNN. Fuente: Elaboración propia.

Codificación y preprocesado de la señal

En este bloque inicial la serie temporal bruta se divide en conjuntos de entrenamiento y prueba, se reinician los índices y se expanden las etiquetas para balancear clases. A continuación, se calculan los valores mínimos, máximos y cuantiles sobre el conjunto de entrenamiento, determinando el número de neuronas

de la capa A. Finalmente, los datos se fragmentan en secuencias de longitud T y se aplica padding al conjunto de prueba para ajustarlo a múltiplos de T . Esta cadena de operaciones garantiza que las entradas al modelo estén normalizadas, codificadas por cuantiles y empaquetadas en batches temporales listos para generar trenes de impulsos.




Figura 3.2: Codificación y preprocesado de la señal. Fuente: Elaboración propia.

3.5.7. Capa convolucional híbrida (SNN-CNN)

La incorporación de una capa convolucional híbrida representa una de las innovaciones más significativas del modelo propuesto, fusionando la eficiencia energética de las SNNs con las capacidades de extracción de características espaciales de las redes neuronales convolucionales. Esta arquitectura híbrida surge tras una exhaustiva exploración de múltiples configuraciones arquitecturales, buscando optimizar tanto el rendimiento predictivo como la viabilidad computacional.

Ubicación de la capa convolucional en la arquitectura

La capa convolucional híbrida se sitúa justo después de la capa B, donde recibe los trenes de impulsos que generan las neuronas LIF recurrentes. De esta forma, puede trabajar con patrones temporales que ya han sido refinados por la dinámica recurrente de la SNN base.

La evidencia experimental respalda esta decisión, las arquitecturas híbridas SNN-CNN obtienen mejores resultados cuando combinan el procesamiento temporal asíncrono de las SNNs con operaciones de convolución espacial [40]. Además, esta configuración preserva la estructura temporal de los impulsos mientras los kernels convolucionales extraen características relevantes.




Figura 3.3: Arquitectura detallada de la capa convolucional híbrida mostrando el flujo desde los impulsos de la capa B hacia el procesamiento convolucional con kernels adaptativos. Fuente: Elaboración propia.

Detalle arquitectural de la capa convolucional híbrida

La figura 3.3 ilustra el flujo específico de procesamiento dentro del núcleo SNN, destacando cómo los trenes de impulsos generados por las neuronas LIF de la capa B son procesados por kernels convolucionales especializados antes de generar las salidas de la capa C. Este procesamiento incluye la aplicación de diferentes tipos de kernels (Gaussiano, Laplaciano, etc.) y los modos de fusión (direct, weighted_sum, max) que permiten la extracción optimizada de características temporales.

Tipos de kernels implementados

La selección de kernels convolucionales para el procesamiento de impulsos requirió una aproximación diferenciada de las CNNs tradicionales. Tras la evaluación sistemática de múltiples configuraciones, se determinó que los kernels 1D con tamaños entre 3 y 7 elementos proporcionan el equilibrio óptimo entre capacidad de captura de patrones temporales y eficiencia computacional.

El uso de un kernel gaussiano para la convolución responde a la necesidad de preservar la estructura temporal, a la vez que se suavizan posibles fluctuaciones debidas a la naturaleza discreta de los impulsos individuales. Este tipo de kernel es ampliamente utilizado en procesamiento de señales neuronales precisamente por su

capacidad para aproximar la respuesta postsináptica biológica y facilitar el análisis cuantitativo.

Los kernels implementados operan sobre ventanas temporales deslizantes, donde cada kernel K_i de tamaño k procesa secuencias de impulsos según:

$$S_{\text{conv}}(t) = \sum_{j=0}^{k-1} K_i(j) \cdot S_{\text{input}}(t - j) \quad (3.1)$$

donde $S_{\text{input}}(t)$ representa el tren de impulsos de entrada y $S_{\text{conv}}(t)$ la salida convolucionada.

Conversión de Impulsos a Tensor y Gradientes

Mecanismo de Conversión La conversión de trenes de impulsos discretos a representaciones tensoriales continuas se implementa mediante :

```
conv_spikes = F.conv1d(b_spikes_sum, kernel, padding='same')
```

Esta operación toma como entrada la suma temporal de los impulsos generados por la capa B de la red y aplica dicho kernel gaussiano. El resultado es una señal continua, suavizada, que preserva tanto la información temporal como la amplitud relativa de impulsos. La elección del padding 'same' asegura que la longitud de la señal de salida coincida con la original, facilitando comparaciones directas.

Este procedimiento es fundamental para poder comparar, analizar y visualizar las salidas de SNN en términos equivalentes a los de modelos tradicionales de (ANNs) con los que serán comparados.

3.5.8. Complejidad computacional

En esta subsección, se analiza la complejidad computacional del modelo propuesto basado en SNN. Se proporcionan ecuaciones para el cálculo de operaciones MACs en cada sub-bloque de la arquitectura.

Estimación del número de operaciones MAC ejecutadas

El número de operaciones MAC ejecutadas por un modelo es un parámetro clave para la estimación de su eficiencia energética.

Estimación de MACs para SNNs

Las SNNs realizan operaciones MAC cuando los voltajes neuronales se actualizan o cuando se emite un impulso. Por tanto, en cada paso temporal se ejecutan:

- Operaciones MAC proporcionales al número total de neuronas: $N_A + N_B + N_C$, siendo:
 - N_A : número de neuronas en la capa de entrada.
 - N_B : neuronas en la capa LIF (100, 200, 400).
 - N_C : neuronas en la capa C (igual a N_B).
- Operaciones inducidas por impulsos:
 - N_A operaciones por impulso en la entrada A.
 - N_B operaciones por cada impulso en la capa B (conexiones recurrentes).
 - $K \times N_B$ operaciones adicionales si se usa la capa C, siendo K el tamaño del *kernel*.

En conjunto, el número total de operaciones por instante temporal es:

$$MAC_{SNN} = (N_A + N_B + N_C) + s \times (N_A \times N_B + N_B^2 + K \times N_B) \quad (3.2)$$

donde s es el número de impulsos generados en la capa B por instante (estimado entre 5–10 % de N_B). Si T es la longitud temporal (e.g., $T = 250$), entonces:

$$MAC_{SNN}^{seq} = T \times MAC_{SNN} \quad (3.3)$$

lo cual resulta en un rango estimado de 10^6 – 10^7 operaciones MAC por inferencia.

3.6. Preprocesamiento de datos para SNN

En primer lugar, se buscó desarrollar flujos de preprocesamiento estandarizados que pudieran manejar la heterogeneidad inherente a los datos de series temporales utilizados en aplicaciones de detección de anomalías [41]. En segundo lugar, se planteó la necesidad de crear algoritmos de normalización temporal que preservaran

las características críticas para la codificación de impulsos, considerando que las SNNs requieren enfoques de codificación específicos para convertir datos continuos en trenes de impulsos discretos [6]. Como objetivo adicional, se implementó metodologías de completado de datos que mantuvieran la coherencia temporal necesaria para el entrenamiento efectivo de modelos basados en STDP.

3.6.1. Implementación de flujos de preprocesamiento para dataset IOPS

El dataset IOPS contiene indicadores clave de rendimiento (KPIs) de diferentes servicios y presenta patrones temporales heterogéneos que incluyen comportamientos cíclicos, estables e inestables, por lo que el desarrollo de flujos de preprocesamiento se centró en abordar esta heterogeneidad.

La implementación se estructuró en módulos especializados que abordan cada aspecto del preprocesamiento de manera independiente pero coordinada. El módulo `iops_check_different_KPIs` fue diseñado para identificar y catalogar los diferentes tipos de KPIs presentes en el dataset, reconociendo que cada métrica requiere estrategias de normalización específicas debido a sus rangos de valores y características estadísticas particulares. El módulo `create_new_dataset_per_every_different_kpi` implementa la segregación de datos por tipo de KPI, facilitando el procesamiento paralelo y la optimización específica para cada métrica.

La funcionalidad de completado de datos faltantes se implementó mediante el módulo `iops_fill_missing_timestamps`, que utiliza algoritmos de interpolación temporal para mantener la regularidad necesaria en las series temporales. Este módulo incorpora verificación de intervalos regulares y añade las observaciones necesarias con valores neutros cuando se detectan gaps temporales, preservando la integridad estructural requerida para la codificación de impulsos en SNNs.

3.6.2. Implementación de flujos de preprocesamiento para dataset Callt2

El dataset Callt2, que registra flujos de personas en el edificio Callt2 de Universidad de California, presenta características únicas que requirieron el desarrollo de algoritmos de preprocesamiento especializados [42]. Este dataset contiene 10,080

observaciones que abarcan 15 semanas con 48 intervalos temporales por día, representando mediciones cada media hora de flujos de entrada y salida de personas [42].

El módulo `CalIt2_transform_date_to_timestamp` implementa la conversión de formatos de fecha a representaciones timestamp uniformes, asegurando compatibilidad con los sistemas de codificación temporal de BindsNET. La verificación de duplicación de datos se realiza mediante `CalIt2_check_every_row_is_repeated_2_times`, que confirma la presencia de dos streams de datos por cada timestamp (entrada y salida de personas).

El algoritmo de detección y etiquetado de anomalías implementado en `CalIt2_fill_label_field` utiliza criterios basados en umbrales de conteo de personas y proximidad temporal a eventos conocidos. Este módulo incorpora lógica de clasificación que considera múltiples factores: el número de personas, la dirección del flujo (entrada/salida), y la coincidencia temporal con eventos registrados, aplicando una ventana de tolerancia de 15 minutos para determinar la proximidad a eventos.

3.6.3. Algoritmos de normalización temporal

Los algoritmos de normalización temporal, incluyendo el completado de gaps temporales, se implementaron utilizando estrategias adaptativas que consideran el contexto local de cada serie temporal. Para gaps de corta duración (menos de 3 observaciones consecutivas), se aplicó interpolación lineal, mientras que para gaps más extensos se utilizó imputación basada en patrones estacionales identificados en la serie. Esta aproximación híbrida demostró ser efectiva para mantener la coherencia temporal necesaria para el entrenamiento de modelos SNN con STDP.

3.6.4. Arquitectura modular y reutilizable del código

La arquitectura del código desarrollado siguió principios de diseño modular que facilitan la reutilización y extensión para diferentes tipos de datasets. Cada módulo de preprocesamiento se diseñó como una unidad funcional independiente con interfaces estandarizadas, permitiendo la composición flexible de flujos de procesamiento según las características específicas de cada dataset.

La implementación incorpora patrones de diseño que promueven la separación de responsabilidades: módulos de validación de datos, transformación, normalización

y etiquetado operan de manera independiente pero coordinada. Esta arquitectura modular facilitó posteriormente la integración con el framework BindsNET y permitió la adaptación de los algoritmos de preprocesamiento para su uso en el presente trabajo de investigación.

Capítulo 4

Resultados

4.1. Descripción de los escenarios experimentales

En este capítulo se presentan los escenarios, configuraciones y protocolos empleados para evaluar los modelos de detección de anomalías. Se comparan:

- **Modelo SNN base (A–B)**: implementación base del trabajo previo.
- **SNN híbrida (A–B–C)**: modelo propuesto con capa convolucional y búsqueda de hiperparámetros.
- **Baselines TSFEDL**: OhShuLih [43], KhanZulfiqar [44], ZhengZhenyu [45], WeiXiaoyan [46].

4.1.1. Datasets y particionado

Se emplean datasets públicos con etiquetas binarias (0: normal, 1: anomalía). Para cada uno:

- **IOPS**: KPI de servicios.
 - Observaciones: *2.788.680 (26 archivos KPI)*.
 - Frecuencia de muestreo: *1 minuto*.
 - Variables: `value`, `label`.
 - Porcentaje de positivos: *1.92 %*.

- Particionado: 50/50 temporal (primera mitad entrenamiento, segunda mitad prueba), preservando orden temporal para evitar fuga de información.
- **Callt2:** flujos de entrada/salida en el edificio Callt2 de la Universidad de California.
 - Observaciones: 10.080 (15 semanas, 48 intervalos/día).
 - Frecuencia de muestreo: 30 minutos.
 - Variables: `value` (univariado por flujo), `label`.
 - Porcentaje de positivos: 24.80 %.
 - Particionado: 50/50 temporal.

Preprocesado común:

- Tipado de columnas: `value` en `float64` y `label` en `Int64`.
- Expansión de etiquetas en entrenamiento (`expansion = 100`) para mitigar desbalanceo temporal.
- Cálculo de cuantiles sobre `train` únicamente: rango extendido con `a = 0,1` y resolución `r = 0,05`; determina `snn_input_layer_neurons_size`.
- Segmentación en ventanas de longitud `T = 250` y *padding* del conjunto de prueba.

4.1.2. Configuración de hardware y software

En este TFM se han utilizado dos entornos de trabajo principales: El Proyecto SNN (con dos variantes internas: modelo SNN base (A–B) y SNN híbrida (A–B–C)) y Baselines TSFEDL.

Ambos entornos no se unificaron deliberadamente debido a incompatibilidades de versiones, particularmente relacionadas con PyTorch, NumPy y Pandas. Intentar forzar una convergencia resultaba inviable, dado que no era posible encontrar una combinación de versiones que permitiera ejecutar simultáneamente ambos proyectos. A continuación se muestran las restricciones técnicas más relevantes:

- **Restricción principal:** BindsNET 0.2.7 requiere una versión de PyTorch anterior a la 1.13, lo que lo hace incompatible con la versiones 2.x requeridas por TSFEDL.

- **Efecto cadena:** librerías estrechamente ligadas, como *Torchvision* y *Lightning/torchmetrics*, demandan rangos de versiones distintos de *torch*, lo que agrava la incompatibilidad.
- **Cambios estructurales:** tanto NumPy 2.x como Pandas 2.x introducen modificaciones internas que obligarían a un proceso de refactorización antes de poder migrar el entorno SNN de manera estable.

Hardware (común a todos los experimentos)

- **CPU:** Intel(R) Core(TM) i7-14700HX
- **GPU:** NVIDIA GeForce RTX 4060 (8 GB VRAM)
- **RAM:** 32 GB
- **Sistema Operativo:** Microsoft Windows 11 Pro (Build 26100)
- **Dispositivo de cómputo:** Seleccionable mediante parámetro `-device {cpu|gpu}`

Comparación de versiones de software

La Tabla 4.1 resume las principales diferencias entre el entorno de TSFEDL y el del Proyecto SNN (aplicable a ambas variantes SNN: original y con capa convolucional).

Librería	TSFEDL	Proyecto SNN	Observación
Python	3.10.0	3.10.0	Mismo
PyTorch	2.7.1+cpu	1.11.0	Diferencia mayor (API / backend)
Torchvision	—	0.12.0	Sólo en SNN
NumPy	2.1.3	1.23.5	Diferencia relevante (cambios internos)
Pandas	2.3.1	1.4.3	Diferencia mayor (funciones depreciadas)
Matplotlib	—	3.5.2	Sólo en SNN (núcleo)
Scikit-learn	—	1.1.1	Sólo en SNN
BindsNET	—	0.2.7	Específico SNN (requiere PyTorch 1.x)

Tabla 4.1: Comparativa principal de versiones de software entre TSFEDL y Proyecto SNN.

Librerías adicionales del Proyecto SNN

Además de las listadas en la tabla, el entorno SNN incluye:

Aprendizaje Profundo / ML: TensorFlow 2.19.0, Keras 3.10.0, PyTorch Lightning 2.5.2, Torchmetrics 1.7.4

Visualización: Matplotlib 3.9.3 (instalada adicionalmente), Pillow 11.0.0, OpenCV 4.10.0.84

Procesamiento de datos: SciPy 1.14.1, Scikit-image 0.24.0, NetworkX 3.4.2

Utilidades: Pytest 8.3.4, Rich 14.0.0, TQDM 4.67.1, Requests 2.32.3

Dominio de señales: ObsPy 1.4.2 (sísmica), WFDB 4.3.0 (biomédica), SoundFile 0.13.1 (audio)

Estrategia de gestión de entornos

Se emplearon entornos virtuales independientes utilizando `venv`.

4.1.3. Diseño experimental de tamaños de capa y protocolo de optimización

Para evaluar el impacto del tamaño de la red sobre el equilibrio rendimiento–coste computacional en la arquitectura híbrida propuesta (Capa B recurrente LIF + Capa C convolucional adaptativa), definimos una rejilla escalonada de tamaños para las capas de procesamiento interno:

$$N_B \in \{100, 200, 400\}, \quad N_C = N_B$$

La elección de una progresión aproximadamente duplicativa (factor $\times 2$) se justifica por:

1. **Cobertura de capacidad con pocos puntos:** Se obtiene un rango total de $4\times$ en número de neuronas con solo tres configuraciones, reduciendo el número de escenarios a optimizar bajo las restricciones temporales del TFM (R1) y de coste computacional (R4).

2. **Análisis de escalado:** La complejidad operacional estimada (ver ecuación de MACs en la [Sección 3.5.8](#)) contiene un término dominante cuadrático en N_B (por N_B^2 y el producto $N_A N_B$), permitiendo observar cómo cambia el régimen de coste con incrementos estructurados.
3. **Zona práctica de capacidad:** Valores por debajo de 100 neuronas tienden a no representar bien los patrones temporales en secuencias con variabilidad contextual, mientras que superar 400 aumenta la latencia y memoria de monitores sin garantizar ganancias proporcionales en F1 dado el carácter univariante / baja dimensionalidad de entrada.
4. **Control de estabilidad dinámica:** Tamaños extremadamente grandes elevan el riesgo de configuraciones subóptimas (redes muy silenciosas o saturadas) durante la fase temprana de la búsqueda bayesiana.

Protocolo de optimización de hiperparámetros

Para cada tamaño N_B ejecutamos 100 ensayos (pruebas) de optimización con Optuna usando:

- Algoritmo TPE para búsqueda adaptativa en un espacio mixto continuo y categórico.
- Mecanismo de poda ASHA para detener configuraciones no prometedoras tempranamente (mitigando el coste de redes silenciosas).
- Métrica objetivo: Minimización de $-\max(F1_B, F1_C)$, priorizando la mejor sinergia entre la capa recurrente y la capa convolucional adaptativa.

Justificación de 100 pruebas por configuración:

1. **Convergencia empírica de TPE:** Los estudios de optimización muestran estabilización de mejoras marginales en intervalos de 50–150 evaluaciones en espacios de dimensión efectiva moderada [[47](#), [34](#)].
2. **Eficiencia con poda:** La integración de ASHA reduce el número de evaluaciones completas necesarias, redirigiendo recursos a configuraciones más prometedoras [[48](#), [36](#)].

3. **Sensibilidad SNN:** En SNNs la interacción entre plasticidad y dinámica de fuga/umbral puede generar regiones amplias de bajo disparo; la poda acelera el descarte [35, 37].
4. **Equidad comparativa:** Mantener el mismo presupuesto de 100 pruebas por cada N_B evita sesgos de sobre-optimización en redes mayores y permite comparar curvas rendimiento/coste de forma homogénea.
5. **Restricciones del proyecto:** 3 escalas de red $\times$ 100 pruebas = 300 ensayos nominales; con poda, el número de ejecuciones completas efectivas disminuye, manteniéndose dentro del límite temporal (R1) y computacional (R4).

Salida registrada por prueba

Para cada ensayo almacenamos: (i) hiperparámetros seleccionados, (ii) métricas $F1_B$, $F1_C$, $\max(F1_B, F1_C)$, (iii) tiempo de ejecución, (iv) identificador de prueba y (v) semilla pseudoaleatoria (cuando aplica) para reproducibilidad.

Criterio de selección final

La configuración óptima por cada N_B se define como aquella con mayor $\max(F1_B, F1_C)$ (equivalente a menor valor objetivo interno). Además, conservamos la traza de la curva de mejor valor acumulado (*best-so-far*) para mostrar la estabilización antes de la prueba 100.

Resumen estructurado

Parámetro	Config. 1	Config. 2	Config. 3
$N_B = N_C$	100	200	400
Pruebas (TPE+ASHA)	100	100	100
Métrica objetivo	$-\max(F1_B, F1_C)$		
Espacio kernel	Tipos + tamaño (3–9) + σ + balance		
Plasticidad	$\nu_1, \nu_2 \in [-0,5, 0,5]$		
Dinámica LIF	threshold, decay		
Fusión	direct / weighted_sum / max		

Síntesis

El diseño adopta un escalado mínimo pero informativo de capacidad (100–400 neuronas) y un presupuesto de 100 evaluaciones por escala que se justifica por evidencia de convergencia de métodos bayesianos con poda. Esto permite el análisis comparativo rendimiento / coste y prepara la extensión futura hacia hardware neuromórfico (ver Sección 5.7.1).

4.1.4. Hiperparámetros y estrategia de búsqueda

La SNN híbrida (A–B–C) se optimizó con Optuna usando TPE maximizando el F1-score:

- **Parámetros neuronales y STDP:**

- $\text{nu1} \in [-0,5, 0,5]$
- $\text{nu2} \in [-0,5, 0,5]$
- $\text{threshold} \in [-65, -50]$
- $\text{decay} \in [80, 150]$

- **Capa convolucional:**

- $\text{kernel_type} \in \{\text{gaussian}, \text{laplacian}, \text{mexican_hat}, \text{box}\}$
- $\text{kernel_size} \in \{3, 5, 7, 9\}$
- $\text{sigma} \in [0, 5, 3, 0]$
- $\text{norm_factor} \in [0, 1, 1, 0]$
- $\text{exc_inh_balance} \in [-0, 3, 0, 3]$
- $\text{conv_processing_type} \in \{\text{direct}, \text{weighted_sum}, \text{max}\}$.

- **Parámetros fijos:**

- $T = 250$
- $\text{expansion} = 100$
- $a = 0,1$
- $r = 0,05$
- $\text{pruebas} = 100$

4.2. Metodología de evaluación

4.2.1. Entorno de ejecución

Aunque la máquina dispone de una GPU NVIDIA GeForce RTX 4060 (8 GB VRAM), no se utilizó aceleración por GPU debido a incompatibilidades prácticas entre el entorno Windows y las dependencias (versionado de CUDA/cuDNN y librerías) requeridas. Por lo tanto, todos los entrenamientos se ejecutaron en CPU. Esta decisión afecta al tiempo de entrenamiento, pero no altera la lógica de los algoritmos ni los hiperparámetros establecidos.

4.2.2. Métricas de calidad

La tarea se evalúa como detección binaria de anomalías (clase positiva: `label = 1`). Se reportan métricas por capa (B y C) cuando aplica, y una métrica principal `best_f1` definida como $\max(F1_B, F1_C)$ en el modelo híbrido.

Definiciones:

- Precisión: $\text{Prec} = \frac{TP}{TP+FP}$.
- Recall: $\text{Rec} = \frac{TP}{TP+FN}$.
- F1-score: $F1 = \frac{2 \cdot \text{Prec} \cdot \text{Rec}}{\text{Prec} + \text{Rec}}$.

Adicionalmente:

- **MSE** por capa (B y C) sobre la señal procesada.

4.2.3. Protocolo de validación

- Particionado temporal 50/50 (sin mezcla) para cada dataset.
- Optimización de hiperparámetros con Optuna sobre el conjunto de entrenamiento; evaluación en prueba.
- En todas las configuraciones se utiliza selección basada en validación sobre el conjunto de entrenamiento, evitando contaminación con el conjunto de prueba.

- Semillas pseudoaleatorias: Se utilizan semillas fijas por prueba para garantizar reproducibilidad, con un único experimento por configuración de red (sin promediado de corridas múltiples debido a restricciones temporales).

4.3. Análisis de resultados

En esta sección se presentan y discuten los resultados, comparando el modelo SNN base (A–B), la SNN híbrida (A–B–C) y modelos TSFEDL [9]. Se incluye análisis por dataset, ablaciones y eficiencia. Los tiempos de entrenamiento reportados deben interpretarse considerando que todos los modelos se ejecutaron en CPU (véase la Sección 4.2.1).

4.3.1. Resultados por dataset

IOPS

Los resultados en el dataset IOPS muestran el desafío que representa detectar anomalías en datos muy desbalanceados (1.92 % de anomalías):

- **Resumen:** La arquitectura híbrida SNN (A–B–C) muestra mejoras importantes sobre el modelo base en IOPS. El mejor resultado híbrido alcanza $F1 = 0.277$ (configuración n_{100}), lo que representa una mejora de 4.6x sobre el modelo SNN base ($F1 = 0.060$), aunque sigue siendo inferior a los baselines TSFEDL.
- **Tendencias:** Los mejores resultados se obtuvieron con kernels `mexican_hat` y `laplacian`, procesamiento `weighted_sum` y `max`, y configuraciones de menor número de neuronas ($n_{100} > n_{200} > n_{400}$), lo que sugiere que redes más grandes tienden a sobreajustarse en este dataset desbalanceado.
- **Errores:** A pesar de las mejoras, sigue siendo complicado lidiar con el desbalanceo extremo. El modelo híbrido logra detectar más anomalías pero mantiene altas tasas de falsos negativos comparado con métodos tradicionales.

Callt2

Los resultados en el dataset Callt2 muestran un rendimiento consistente y aceptable para detección de anomalías (24.80 % de anomalías):

Modelo	N	Prec	Rec	F1	MSE
SNN (A-B)	100	0.049	0.078	0.060	0.643
SNN (A-B)	200	0.052	0.073	0.061	0.594
SNN (A-B)	400	0.054	0.073	0.062	0.581
SNN (A-B-C)	100	0.163	0.725	0.277	0.142
SNN (A-B-C)	200	0.122	0.178	0.144	0.553
SNN (A-B-C)	400	0.079	0.121	0.096	0.600

Tabla 4.2: Resultados de detección de anomalías en dataset IOPS. N representa el número de neuronas en las capas B y C para los modelos SNN. Se muestran los mejores resultados obtenidos tras optimización con Optuna para cada configuración.

Modelo	Prec	Rec	F1	MSE
SNN (A-B)	0.054	0.073	0.062	0.581
SNN (A-B-C)	0.163	0.725	0.277	0.142
TSFEDL-OhShuLih	0.280	0.984	0.436	0.081
TSFEDL-KhanZulfiqar	0.263	0.926	0.410	0.078
TSFEDL-ZhengZhenyu	0.265	0.931	0.412	0.095
TSFEDL-WeiXiaoyan	0.244	0.858	0.380	0.142

Tabla 4.3: Mejores resultados de detección de anomalías en el dataset IOPS. Se muestran las métricas de calidad para cada modelo evaluado.

- **Resumen:** La arquitectura híbrida SNN (A-B-C) mantiene un F1-score estable entre 0.416-0.417 en todas las configuraciones de neuronas (100, 200, 400), mostrando robustez ante el escalado. El mejor resultado es F1 = 0.417 con n_{100} , superando significativamente al modelo SNN base (F1 = 0.239) con una mejora de 1.7x pero quedando por debajo de TSFEDL (F1 = 0.704).
- **Tendencias:** Optuna seleccionó consistentemente kernels `mexican_hat` y `gaussian` con tamaños 5-7, procesamiento `direct`, y valores de `threshold` en el rango [-66.8, -67.7]. Las mejores pruebas se encontraron típicamente entre las evaluaciones 32-75, con duración promedio de 14-42 minutos.
- **Errores:** Recall muy alto (99.4-100 %) pero precisión moderada (26.4 %), lo que resulta en una estrategia conservadora que prioriza detectar todas las anomalías aunque genere falsos positivos—apropiada para aplicaciones donde perder una anomalía es muy costoso.

Modelo	N	Prec	Rec	F1	MSE
SNN (A-B)	100	0.160	0.472	0.239	0.790
SNN (A-B)	200	0.104	0.299	0.155	0.859
SNN (A-B)	400	0.083	0.239	0.124	0.892
SNN (A-B-C)	100	0.263	1.000	0.416	0.737
SNN (A-B-C)	200	0.264	1.000	0.417	0.734
SNN (A-B-C)	400	0.264	0.994	0.417	0.730

Tabla 4.4: Resultados de detección de anomalías en dataset Callt2. N representa el número de neuronas en las capas B y C para los modelos SNN. Se muestran los mejores resultados obtenidos tras optimización con Optuna para cada configuración.

Modelo	Prec	Rec	F1	MSE
SNN (A-B)	0.160	0.472	0.239	0.790
SNN (A-B-C)	0.264	0.999	0.418	0.732
TSFEDL-OhShuLih	0.543	1.000	0.704	0.036
TSFEDL-KhanZulfiqar	0.543	1.000	0.704	0.026
TSFEDL-ZhengZhenyu	0.543	1.000	0.704	0.034
TSFEDL-WeiXiaoyan	0.522	0.970	0.679	0.090

Tabla 4.5: Mejores resultados de detección de anomalías en el dataset Callt2. Se muestran las métricas de calidad para cada modelo evaluado.

4.3.2. Comparación con modelos TSFEDL

Se comparan los siguientes modelos de la librería TSFEDL [9] basándose en los resultados de los experimentos de evaluación:

- **OhShuLih**: Modelo de redes neuronales para detección de anomalías en series temporales
- **KhanZulfiqar**: Enfoque basado en deep learning para análisis temporal
- **ZhengZhenyu**: Arquitectura híbrida para detección de patrones anómalos
- **WeiXiaoyan**: Modelo especializado en series temporales multivariadas

Observaciones:

- **Rendimiento en IOPS**: Los modelos TSFEDL superan a las SNN con F1-scores en el rango 0.380-0.436 vs 0.060-0.277 de las SNN. OhShuLih obtuvo el mejor resultado (F1=0.436), mientras que la mejor SNN híbrida alcanzó F1=0.277, reduciendo parcialmente la brecha respecto al modelo SNN base (F1=0.060).

- **Rendimiento en Calit2:** Los modelos TSFEDL mantienen ventaja con F1-scores de 0.679-0.704 vs 0.239-0.417 de las SNN. La SNN híbrida ($F1=0.417$) se acerca más a los baselines que en IOPS, pero los tres mejores modelos TSFEDL ($F1=0.704$) siguen manteniendo una ventaja del 69 %.
- **Eficiencia:** Las SNN mantienen ventajas potenciales en eficiencia computacional debido a la naturaleza dispersa de los impulsos discretos, aunque validar empíricamente estas ventajas requiere hardware neuromórfico especializado.

Capítulo 5

Conclusiones

5.1. Resumen del trabajo desarrollado

Este TFM ha abordado el problema de detectar anomalías en series temporales usando arquitecturas basadas en SNNs. Se propone una extensión híbrida SNN-CNN que se optimiza automáticamente con Optuna. Se emplean dos datasets con características bastante diferentes: IOPS (muy desbalanceado, solo 1.92 % anomalías) y Callt2 (más balanceado, 24.80 % anomalías). Se aplica un flujo de preprocesamiento que incluye cuantización dinámica por cuantiles expandidos, expansión de etiquetas para compensar el desbalanceo temporal, y segmentación en ventanas de longitud $T=250$. La arquitectura propuesta (A–B–C) integra una capa convolucional parametrizable con kernels gaussiano, laplaciano, mexican hat y box, junto con modos de fusión direct, weighted_sum y max. Se utiliza F1-score como métrica principal, comparando contra el modelo SNN base (A–B) y baselines de TSFEDL [9]. La motivación energética del trabajo se basa en el potencial de las SNNs, especialmente para computación neuromórfica eficiente.

5.2. Grado de cumplimiento de los objetivos

- **Objetivo destacado:** O2 (Diseño y desarrollo de arquitecturas optimizadas): Se logró desarrollar una arquitectura híbrida SNN-CNN con optimización bayesiana automatizada mediante Optuna TPE, ejecutando 100 pruebas por configuración y consiguiendo que los hiperparámetros converjan de forma estable. La optimización automatizada fue clave, ya que permitió explorar sistemáticamente

Objetivo	Estado (Sí/Parcial/No)
O1: Revisión bibliográfica de modelos de SNNs y su aplicación en detección de anomalías y mantenimiento predictivo.	Sí
O2: Diseño y desarrollo de arquitecturas de SNNs optimizadas para la detección de anomalías en datos de sensores industriales.	Sí
O3: Implementación de modelos de SNNs sostenibles que minimicen el consumo energético sin sacrificar la precisión.	Parcial
O4: Validación de los modelos desarrollados mediante experimentación en conjuntos de datos reales de mantenimiento predictivo.	Sí
O5: Comparación de la eficiencia energética y el rendimiento predictivo frente a modelos tradicionales de detección de anomalías.	Sí

Tabla 5.1: Resumen del grado de cumplimiento de los objetivos planteados.

el espacio de parámetros neuronales y convolucionales.

- **Objetivo cumplido parcialmente:** O3 (Implementación sostenible): Se desarrolló el análisis teórico de eficiencia mediante estimación de MACs, pero no se pudo validar en hardware neuromórfico por limitaciones de acceso.

5.3. Principales contribuciones

1. Propuesta e implementación de una arquitectura híbrida SNN-CNN con capa convolucional parametrizable (kernels gaussiano, laplaciano, mexican hat, box) y modos de fusión (direct, weighted_sum, max), desarrollada mediante optimización bayesiana (Optuna TPE) sobre parámetros neuronales (threshold, decay), de plasticidad (nu1, nu2).
2. Flujo de preprocesamiento reproducible: cuantización dinámica por cuantiles expandidos, expansión de etiquetas para mejorar la cobertura de eventos anómalos, y segmentación temporal en ventanas de longitud.
3. Comparativa empírica contra el modelo base (SNN A-B) y contra baselines de TSFEDL mostrando que, aunque los modelos TSFEDL tienen mejor rendimiento (F1=0.436 vs 0.277 en IOPS, F1=0.704 vs 0.417 en Callt2), las SNN mantienen ventajas en eficiencia y potencial para computación neuromórfica.

4. Análisis preliminar de complejidad computacional, sentando bases para evaluación energética futura en hardware neuromórfico.
5. Almacenamiento estructurado de configuraciones para reproducibilidad.

5.4. Discusión de resultados

Los resultados del análisis experimental muestran que:

- La capa convolucional mejora bastante el F1-score respecto a la SNN base en datasets muy desbalanceados como IOPS (4.6x, de 0.060 a 0.277), aunque el rendimiento depende del número de neuronas ($n_{100} > n_{200} > n_{400}$). En Callt2 se mantiene estable con F1-scores alrededor de 0.416-0.417 independientemente del número de neuronas (100-400).
- El modo de procesamiento `direct` fue elegido consistentemente por Optuna como óptimo en Callt2, junto con kernels `mexican_hat` y `gaussian` con tamaños 5-7, lo que indica preferencia por suavizado espacial. En cambio, IOPS favoreció `weighted_sum` y `max` con kernels `laplacian` y `mexican_hat`, sugiriendo que se necesita detección de bordes para anomalías de sistema más bruscas.
- Los parámetros `threshold` (rango [-66.8, -67.7]) y `decay` (rango [73.6-139.8]) son los más influyentes según las optimizaciones de Optuna, seguidos de `kernel_size` y `sigma`, confirmando la importancia de la dinámica neuronal LIF.
- Los modelos TSFEDL (OhShuLih, KhanZulfiqar, ZhengZhenyu, WeiXiaoyan) superan consistentemente a las SNN en ambos datasets, con diferencias más marcadas en IOPS debido al desbalanceo extremo que las SNN no logran manejar bien.

5.4.1. Implicaciones prácticas

El modelo híbrido desarrollado tiene potencial para aplicaciones reales de mantenimiento predictivo y monitorización IoT, especialmente en entornos con restricciones energéticas. La arquitectura basada en impulsos discretos es naturalmente compatible con hardware neuromórfico de bajo consumo y su naturaleza dispersa sugiere que podría procesarse de forma eficiente, aunque habría que hacer mediciones específicas de rendimiento temporal para validar su viabilidad en

aplicaciones de tiempo real. En mantenimiento predictivo, el alto recall observado (99.9 % en Callt2) es crucial para evitar fallos no detectados, aunque la baja precisión requiere sistemas de post-procesado para reducir falsas alarmas.

5.5. Limitaciones y consideraciones de validez

5.5.1. Limitaciones experimentales

- **Particionado 50/50:** La falta de validación cruzada temporal podría introducir sesgos en la generalización.
- **Estimación energética indirecta:** No medimos el consumo real en hardware neuromórfico (solo estimaciones analíticas de MACs).
- **Escalabilidad multivariante:** Los experimentos se centraron principalmente en señales univariadas (o pocas variables); falta evaluar en entornos fuertemente multivariados.
- **GPU:** Uno de los motivos para elegir BindsNET fue poder aprovechar la aceleración GPU; sin embargo, no conseguimos una configuración estable (incompatibilidades de dependencias en Windows), lo que aumentó la duración de los entrenamientos y limitó la exploración de hiperparámetros. Esto podría significar que no identificamos todas las combinaciones óptimas. Aún así, como todos los modelos se ejecutaron bajo condiciones homogéneas (CPU) y el preprocesamiento fue uniforme, la validez interna de la comparación se mantiene. Futuros trabajos en un entorno Linux con soporte CUDA habilitado permitirán ampliar la búsqueda y evaluar la robustez frente a una exploración más exhaustiva.

5.5.2. Consideraciones de validez

- **Interna:** La expansión de etiquetas podría inflar artificialmente el recall si no se aplica de forma consistente en inferencia.
- **Externa:** Los datasets (IOPS, Callt2) puede que no representen toda la diversidad industrial (ciclos estacionales largos, variabilidad contextual).

- **Baselines:** Las comparaciones con TSFEDL se limitaron a cuatro modelos específicos (OhShuLih, KhanZulfiqar, ZhengZhenyu, WeiXiaoyan), sin acceso a mediciones de consumo energético de los baselines.

5.6. Conclusiones finales

En resumen, este trabajo ha demostrado que las arquitecturas híbridas SNN-CNN, aunque no superan consistentemente a los métodos de deep learning tradicionales en términos de F1-score, ofrecen un equilibrio interesante entre rendimiento y eficiencia computacional. La arquitectura propuesta logró F1-scores de 0.417 en Callt2, manteniéndose competitiva en datasets moderadamente balanceados, mientras que en IOPS mostró mejoras notables respecto al modelo SNN base (4.6x) pero sigue teniendo limitaciones frente a métodos tradicionales en escenarios de desbalanceo extremo.

La optimización bayesiana con Optuna demostró ser una herramienta fundamental para ajustar bien las arquitecturas SNN complejas, permitiendo explorar sistemáticamente el espacio de hiperparámetros neuronales y convolucionales. El modelo presenta características arquitecturales que sugieren potencial para aplicaciones de edge computing, especialmente cuando se despliegue en hardware neuromórfico dedicado donde las ventajas energéticas pueden aprovecharse plenamente, aunque hace falta hacer mediciones específicas de rendimiento temporal en futuros trabajos.

La metodología desarrollada sienta bases sólidas para trabajos futuros en detección de anomalías con SNNs, proporcionando un flujo reproducible de preprocesamiento, optimización y evaluación que se puede extender a otros dominios y arquitecturas neuromórficas más avanzadas. Estos hallazgos apoyan la hipótesis de que integrar mecanismos convolucionales y optimización sistemática reduce la brecha entre SNN y enfoques ANN tradicionales para detección de anomalías en series temporales.

5.7. Trabajos futuros

5.7.1. Evaluación energética y despliegue neuromórfico

Línea prioritaria para validar empíricamente las estimaciones de eficiencia ejecutando en hardware neuromórfico dedicado:

- **Plataformas candidatas:** Intel Loihi 2, SpiNNaker 2, BrainScaleS-2, chips basados en memristores emergentes.
- **Portado del modelo:** Conversión de parámetros LIF y topología a formato compatible (e.g. NxSDK / Lava para Loihi).
- **Métricas energéticas:** Joules por inferencia, mW promedio, latencia por ventana T , escalabilidad en número de neuronas vs. consumo.
- **Comparativa energética:** Medición directa frente a implementaciones GPU/CPU para cuantificar las ventajas reales del paradigma neuromórfico.

5.7.2. Optimización técnica

- **Validación cruzada temporal:** Implementar estrategias como rolling-origin o nested backtesting para hacer más robusta la estimación de generalización.
- **Optimización multiobjetivo:** Extender la optimización con Optuna a objetivos conjuntos (F1 y coste computacional/MACs), usando algoritmos como NSGA-II.
- **Datasets multivariantes industriales:** Incorporar señales de vibración, temperatura y presión para validar la aplicabilidad en mantenimiento predictivo real.

5.7.3. Despliegue y monitorización neuromórfica

Integración específica para sistemas SNN en producción:

- **Monitorización de dispersidad:** Seguimiento continuo de patrones de actividad neuronal para detectar degradación de eficiencia o deriva del comportamiento.

- **Re-calibración de umbrales:** Ajuste automático de umbrales neuronales basado en la distribución reciente de impulsos para mantener sensibilidad sin re-entrenar completamente.
- **Despliegue edge:** Empaquetado optimizado para microcontroladores con soporte SNN nativo (e.g. neuromorphic inference engines) incluyendo cuantización de parámetros sinápticos.
- **Flujo neuromórfico:** Versionado de topologías de red y pesos sinápticos con herramientas específicas para arquitecturas basadas en impulsos.

Apéndice A

Manual de instalación y configuración técnica

A.1. Instalación y configuración de BindsNET

La instalación y configuración de BindsNET presentó desafíos técnicos significativos relacionados con la gestión de dependencias y compatibilidad de versiones. Este anexo documenta los problemas encontrados y las estrategias de resolución implementadas para facilitar la reproducibilidad del entorno de desarrollo.

A.1.1. Problemas de compatibilidad y configuración del entorno

El problema principal surgió con los requisitos de versión de Python, donde BindsNET 0.3.2 requería Python ≥ 3.9 y < 3.12 , mientras que el entorno de desarrollo inicial utilizaba Python 3.8.10.

Los conflictos de dependencias se extendieron a la gestión de paquetes, particularmente con problemas en la versión de pip que impedían la instalación correcta del framework. El error específico `ImportError: cannot import name 'html5lib' from 'pip._vendor'` indicaba incompatibilidades en el sistema de gestión de paquetes que requerían resolución antes de proceder con la instalación de BindsNET.

A.1.2. Estrategias de resolución implementadas

La estrategia implementada consistió en la desinstalación y reinstalación de WSL, proporcionando un entorno limpio y controlado para la instalación de BindsNET.

El proceso de resolución incluyó la actualización de repositorios de paquetes mediante la adición del PPA de deadsnakes [49], permitiendo acceso a versiones específicas de Python compatibles con BindsNET. La instalación de herramientas de desarrollo necesarias, incluyendo python3.10 y herramientas de compilación, se realizó de manera secuencial para evitar conflictos adicionales.

La verificación de la instalación se realizó mediante la ejecución de casos de prueba incluidos en la documentación de BindsNET, confirmando la funcionalidad correcta del framework en el nuevo entorno.

Los experimentos definitivos se consolidaron con BindsNET 0.2.7 sobre PyTorch 1.11.0 debido a la estabilidad de las dependencias y a la necesidad de reproducibilidad exacta. Todas las métricas reportadas en este trabajo para SNN provienen de esa combinación de versiones.

Apéndice B

Bibliografía

- [1] I. X. Vázquez, J. Sedano, M. Afzal, and A. M. García-Vico. Vacuum spiker: A spiking neural network-based model for efficient anomaly detection in time series. <https://arxiv.org/abs/2510.06910>, 2024. arXiv:2510.06910 [cs.NE].
- [2] Barasha Mali. Comparison of the statistical and autoencoder approach for anomaly detection in big data. In *2024 5th International Conference on Big Data Analytics and Practices (IBDAP)*, pages 22–25.
- [3] Yann Cherdo, Benoit Miramond, and Alain Pegatoquet. Time series prediction and anomaly detection with recurrent spiking neural networks. In *2023 International Joint Conference on Neural Networks (IJCNN)*, pages 1–10. ISSN: 2161-4407.
- [4] Shreya Kshirasagar, Benjamin Cramer, Andre Guntoro, and Christian Mayr. Auditory anomaly detection using recurrent spiking neural networks. In *2024 IEEE 6th International Conference on AI Circuits and Systems (AICAS)*, pages 278–281. ISSN: 2834-9857.
- [5] Douglas Z. Plummer, Emily D'Alessandro, Aidan Burrowes, Joshua Fleischer, Alexander M. Heard, and Yingying Wu. 2d spintronics for neuromorphic computing with scalability and energy efficiency. 15(2):16. Number: 2 Publisher: Multidisciplinary Digital Publishing Institute.
- [6] Changze Lv, Yansen Wang, Dongqi Han, Xiaoqing Zheng, Xuanjing Huang, and Dongsheng Li. Efficient and effective time-series forecasting with spiking neural networks.
- [7] Bariah Yusob, Zuriani Mustaffa, and Junaida Sulaiman. Anomaly detection in time series data using spiking neural network. 24(10):7572–7576.

- [8] Dennis Bäßler, Tobias Kortus, and Gabriele Gühring. Unsupervised anomaly detection in multivariate time series with online evolving spiking neural networks. 111(4):1377–1408.
- [9] Ignacio Aguilera-Martos, Ángel M. García-Vico, Julián Luengo, Sergio Damas, Francisco J. Melero, José Javier Valle-Alonso, and Francisco Herrera. TSFEDL: A python library for time series spatio-temporal feature extraction and prediction using deep learning. *Neurocomputing*, 517:223–228, 2023.
- [10] Talent.com. Salario, 2024.
- [11] W. A. Shewhart. *Economic control of quality of manufactured product*. Economic control of quality of manufactured product. Van Nostrand. Pages: 515.
- [12] E. S. Page. Continuous inspection schemes. 41(1):100–115. Publisher: [Oxford University Press, Biometrika Trust].
- [13] Gabriele Gualandi and Alessandro V. Papadopoulos. Worst-case impact assessment of multi-alarm stealth attacks against control systems with CUSUM-based anomaly detection. In *2023 IEEE International Conference on Autonomic Computing and Self-Organizing Systems (ACSOS)*, pages 117–126.
- [14] Gabriele Gualandi, Martina Maggio, and Alessandro Vittorio Papadopoulos. Optimization-based attack against control systems with CUSUM-based anomaly detection. In *2022 30th Mediterranean Conference on Control and Automation (MED)*, pages 896–901. ISSN: 2473-3504.
- [15] Laurence Morissette and Sylvain Chartier. The k-means clustering technique: General considerations and implementation in mathematica. 9(1):15–24.
- [16] RB CLEVELAND. STL : A seasonal-trend decomposition procedure based on loess. 6:3–73.
- [17] Ryan P. Hafen, David E. Anderson, William S. Cleveland, Ross Maciejewski, David S. Ebert, Ahmad Abusalah, Mohamed Yakout, Mourad Ouzzani, and Shaun J. Grannis. Syndromic surveillance: STL for modeling, visualizing, and monitoring disease counts. 9(1):21.
- [18] G. E. Hinton and R. R. Salakhutdinov. Reducing the dimensionality of data with neural networks. 313(5786):504–507. Publisher: American Association for the Advancement of Science.

- [19] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. 9(8):1735–1780.
- [20] Qi Xia, Badjie Ansu, Jianbin Gao, Mupoyi Ntuala Grace, Hu Xia, and Obiri Isaac Amankona. A novel time series approach to anomaly detection and correction for complex blockchain transaction networks. In *2024 IEEE 23rd International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom)*, pages 674–682. ISSN: 2324-9013.
- [21] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes.
- [22] Xiao Zhang, Shuqing Xu, Huashan Chen, Zekai Chen, Fuzhen Zhuang, Hui Xiong, and Dongxiao Yu. Rethinking robust multivariate time series anomaly detection: A hierarchical spatio-temporal variational perspective. 36(12):9136–9149.
- [23] Chenming Yang, Liang Zhou, Hui Wen, Zhiheng Zhou, and Yue Wu. H-VGRAE: A hierarchical stochastic spatial-temporal embedding method for robust anomaly detection in dynamic networks.
- [24] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding.
- [25] Kexin Zhang, Qingsong Wen, Chaoli Zhang, Liang Sun, and Yong Liu. Skip-step contrastive predictive coding for time series anomaly detection. In *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 7065–7069. ISSN: 2379-190X.
- [26] Wulfram Gerstner, Werner M. Kistler, Richard Naud, and Liam Paninski. *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*. Cambridge University Press, Cambridge, UK, 2014.
- [27] Peter Dayan and Laurence F. Abbott. *Theoretical Neuroscience: Computational and Mathematical Modeling of Neural Systems*. MIT Press, Cambridge, MA, 2001.
- [28] Nicolas Skatchkovsky, Hyeryung Jang, and Osvaldo Simeone. Bayesian continual learning via spiking neural networks. 16. Publisher: Frontiers.
- [29] Hatem Haddad, Feres Jerbi, and Issam Smaali. Comparative analysis of off-the-shelf methods for energy consumption anomaly detection. In *2024 10th International Conference on Automation, Robotics and Applications (ICARA)*, pages 392–396. ISSN: 2767-7745.

- [30] Hyeryung Jang, Nicolas Skatchkovsky, and Osvaldo Simeone. BiSNN: Training spiking neural networks with binary weights via bayesian learning. In *2021 IEEE Data Science and Learning Workshop (DSLW)*, pages 1–6.
- [31] Srujana Maddula, Himanshu Gupta, and Shaik Mohammad Jani Basha. AI-driven neuromorphic computing for energy-efficient anomaly detection in IoT networks. 8(3).
- [32] Riadul Islam, Patrick Majurski, Jun Kwon, Anurag Sharma, and Sri Ranga Sai Krishna Tummala. Benchmarking artificial neural network architectures for high-performance spiking neural networks. 24(4):1329. Number: 4 Publisher: Multidisciplinary Digital Publishing Institute.
- [33] Dhruvajyoti Kaushik. Optuna: The smarter way to optimize your machine learning models.
- [34] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD '19*, pages 2623–2631, New York, NY, USA, 2019. ACM.
- [35] Thomas Firmin, Pierre Boulet, and El-Ghazali Talbi. Parallel hyperparameter optimization of spiking neural network.
- [36] BroutonLab. Efficient hyperparameter optimization with optuna framework.
- [37] Maryam Parsa, J. Parker Mitchell, Catherine D. Schuman, Robert M. Patton, Thomas E. Potok, and Kaushik Roy. Bayesian-based hyperparameter optimization for spiking neuromorphic systems. In *2019 IEEE International Conference on Big Data (Big Data)*, pages 4472–4478. IEEE.
- [38] Hananel Hazan, Daniel J. Saunders, Hassaan Khan, Devdhar Patel, Darpan T. Sanghavi, Hava T. Siegelmann, and Robert Kozma. Bindsnet: A machine learning-oriented spiking neural networks library in python. *Frontiers in Neuroinformatics*, 12:89, 2018.
- [39] BindsNET Contributors. Bindsnet documentation. <https://bindsnet-docs.readthedocs.io/>, 2024. Accessed: 2025-07-12.
- [40] Sanaullah Sanaullah. A hybrid spiking-convolutional neural network approach for advancing machine learning models. In *Proceedings of the 5th Northern Lights Deep Learning Conference ({NLDL})*, pages 220–227. PMLR. ISSN: 2640-3498.

- [41] Milvus. What preprocessing techniques are used in anomaly detection? <https://milvus.io/ai-quick-reference/what-preprocessing-techniques-are-used-in-anomaly-detection/>, 2025. Consultado el 12 de julio de 2025.
- [42] UCI Machine Learning Repository. Calit2 building people counts data set, 2009. Accessed: 2025-07-12.
- [43] Shu Lih Oh, Eddie Y. K. Ng, Ru San Tan, and U. Rajendra Acharya. Automated diagnosis of arrhythmia using combination of cnn and lstm techniques with variable length heart beats. *Computers in Biology and Medicine*, 102:278–287, 2018. Implementado en librería TSFEDL.
- [44] M. Sajjad, Z. A. Khan, A. Ullah, T. Hussain, W. Ullah, M. Y. Lee, and S. W. Baik. A novel cnn-gru-based hybrid approach for short-term residential load forecasting. *IEEE Access*, 8:143759–143768, 2020. Implementado en librería TSFEDL.
- [45] Z. Zheng, Z. Chen, F. Hu, J. Zhu, Q. Tang, and Y. Liang. An automatic diagnosis of arrhythmias using a combination of cnn and lstm technology. *Electronics*, 9(1):121, 2020. Implementado en librería TSFEDL.
- [46] Xiaoyan Wei, Limeng Zhou, Zhenghua Chen, and Luping Zhang. Early prediction of epileptic seizures using a long-term recurrent convolutional network. *Journal of Neuroscience Methods*, 327:108395, 2019. Implementado en librería TSFEDL.
- [47] James Bergstra and Yoshua Bengio. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13(Feb):281–305, 2012.
- [48] Richard Liaw, Eric Liang, Tristan Liaw, William Dramé, Robert Nishihara, Philipp Moritz, Ken Goldberg, and Ion Stoica. A system for massively parallel hyperparameter tuning. In *Proceedings of Machine Learning and Systems*, volume 2, pages 230–246, 2020.
- [49] deadsnakes. deadsnakes github organization. <https://github.com/deadsnakes>, 2025. Accessed: 2025-07-12.
- [50] John H. Holland. *Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence*. MIT Press, Cambridge, MA, USA, 2nd edition, 1992.
- [51] Jasper Snoek, H. Larochelle, and Ryan P. Adams. Practical bayesian optimization of machine learning algorithms.

- [52] Jinsheng Yang, Yuanhai Shao, and Chun-Na Li. CNTS: Cooperative network for time series. 11:31941–31950.
- [53] Wolfgang Maass. Networks of spiking neurons: The third generation of neural network models. 10(9):1659–1671.
- [54] Henry Markram, Wulfram Gerstner, and Per Jesper Sjöström. A history of spike-timing-dependent plasticity. 3:4.
- [55] Giacomo Indiveri, Bernabe Linares-Barranco, Tara Julia Hamilton, André van Schaik, Ralph Etienne-Cummings, Tobi Delbruck, Shih-Chii Liu, Piotr Dudek, Philipp Häfliger, Sylvie Renaud, Johannes Schemmel, Gert Cauwenberghs, John Arthur, Kai Hynna, Fopefolu Folowosele, Sylvain Saïghi, Teresa Serrano-Gotarredona, Jayawan Wijekoon, Yingxue Wang, and Kwabena Boahen. Neuromorphic silicon neuron circuits. 5. Publisher: Frontiers.
- [56] Wo Jae Lee, Karim Helwani, A. Krishnaswamy, and S. Tenneti. Robust audio anomaly detection.
- [57] Ying Liu, Zhiyuan Chen, Wentao Zhao, Tianhao Zhao, Tianyu Jia, Zhixuan Wang, Ru Huang, Le Ye, and Yufei Ma. Sparsity-aware in-memory neuromorphic computing unit with configurable topology of hybrid spiking and artificial neural network. 71(6):2660–2673.
- [58] Alexander Lavin and Subutai Ahmad. Evaluating real-time anomaly detection algorithms – the numenta anomaly benchmark. In *2015 IEEE 14th International Conference on Machine Learning and Applications (ICMLA)*, pages 38–44.
- [59] Renjie Wu and Eamonn J. Keogh. Current time series anomaly detection benchmarks are flawed and are creating the illusion of progress. 35(3):2421–2429.