

Modelos de Inteligencia Artificial Sostenible para Mantenimiento Predictivo

Trabajo Fin de Máster

Autor: Javier González Santos

Director: Prof. D. Ángel Miguel García

Máster en Ingeniería Informática

Escuela Politécnica Superior de Jaén

Índice

1. **Motivación** — El problema de la detección de anomalías
2. **Objetivos** — Metas del proyecto
3. **Estado del Arte** — SNNs y arquitecturas existentes
4. **Metodología** — Arquitectura híbrida SNN-CNN
5. **Preprocesamiento** — Flujo de datos reproducible
6. **Resultados Experimentales** — IOPS y CalIt2
7. **Discusión** — Análisis e implicaciones
8. **Conclusiones y Trabajos Futuros**

Motivación

El desafío de la detección de anomalías

- Problema **transversal**: monitorización de redes, mantenimiento predictivo, infraestructuras críticas
- Los datos crecen **exponencialmente** → necesidad de procesamiento eficiente
- Anomalías: picos inusuales, cambios bruscos de tendencia, alteraciones periódicas

Limitaciones de los enfoques tradicionales

- Deep learning convencional: buen rendimiento pero **alto consumo energético**
- Escalabilidad limitada en **dispositivos edge** con recursos restringidos
- Necesidad de procesamiento en **tiempo real**



Propuesta: SNNs como alternativa eficiente que imita la dinámica cerebral

Objetivos del Proyecto

Código	Objetivo	Estado
O1	Revisión bibliográfica de SNNs para detección de anomalías	✅ Sí
O2	Diseño de arquitecturas SNN optimizadas	✅ Sí
O3	Implementación de modelos sostenibles (eficiencia energética)	⚠️ Parcial
O4	Validación en datasets reales de mantenimiento predictivo	✅ Sí
O5	Comparación con modelos tradicionales	✅ Sí

Objetivo destacado (O2): Arquitectura híbrida SNN-CNN con optimización bayesiana automatizada (Optuna TPE)

Estado del Arte — Redes Neuronales de Impulsos

¿Qué diferencia a las SNNs de las ANNs tradicionales?

Aspecto	ANN Tradicional	SNN
Comunicación	Valores continuos (0.0 - 1.0)	Impulsos discretos
Información temporal	El momento no importa	El tiempo del impulso es información
Activación	Todas las neuronas procesan siempre	Solo procesa al recibir impulso
Operaciones	Multiplicaciones intensivas	Sumas y comparaciones

Modelo neuronal LIF (Leaky Integrate-and-Fire)


$$V(t + 1) = V(t) + \alpha(V_{\text{rest}} - V(t)) + I_{\text{entrada}}(t)$$

Si $V(t + 1) \geq V_{\text{threshold}}$ → la neurona **dispara** y se reinicia

Estado del Arte — Arquitectura SNN Base

Modelo bicapa A–B (punto de partida)

- **Capa A (entrada):** 39 neuronas, codificación por cuantiles
- **Capa B (procesamiento):** 100 neuronas LIF, conexiones recurrentes
- **Aprendizaje:** STDP modificado con penalización bidireccional



Metodología — Arquitectura Híbrida SNN-CNN


Innovación principal: Capa convolucional C

- **Arquitectura A–B–C:** Se añade capa convolucional tras la capa B
- **Kernels configurables:**
 - Gaussiano (suavizado)
 - Laplaciano (detección de bordes)
 - Mexican Hat (características con supresión lateral)
 - Box (promediado simple)

Modos de procesamiento

Modo	Descripción
direct	Usa directamente impulsos de capa C
weighted_sum	$0.3 \times B + 0.7 \times C$

Metodología — Diagrama de Arquitectura



Flujo: Señal temporal → Codificación por cuantiles → Capa A → Capa B (LIF+STDP) → Capa C (Convolucional) → Decisión dual

Metodología — Optimización con Optuna

Parámetros optimizados automáticamente

Parámetros neuronales:

- `threshold` $\in [-65, -50]$ mV
- `decay` $\in [80, 150]$
- `nu1`, `nu2` $\in [-0.5, 0.5]$

Parámetros convolucionales:

- `kernel_size` $\in [3, 9]$ (impares)
- `sigma` $\in [0.5, 3.0]$
- `norm_factor` $\in [0.1, 1.0]$


Configuración experimental

- 100 pruebas por configuración
- 3 tamaños de red: 100, 200 y 400 neuronas
- Métrica objetivo: Maximizar F1-score
- Integración MLOps: Weights & Biases

Metodología — Preprocesamiento

Flujo reproducible

1. Particionado 50/50 temporal (sin shuffle)
2. Cuantización dinámica por cuantiles expandidos
3. Expansión de etiquetas para compensar desbalanceo
4. Segmentación en ventanas de longitud $T=250$



Datasets Utilizados

Característica	IOPS	Callt2
Dominio	Métricas de infraestructura	Flujo de personas en edificio
% Anomalías	1.92% (muy desbalanceado)	24.80% (moderado)
Desafío principal	Desbalanceo extremo	Variabilidad temporal

Justificación

- Representan escenarios **reales** de mantenimiento predictivo
- Permiten evaluar robustez ante **diferentes niveles de desbalanceo**

Resultados — Dataset IOPS

Mejora de 4.6x sobre modelo base

Modelo	N	Precisión	Recall	F1	MSE
SNN (A–B)	100	0.049	0.078	0.060	0.643
SNN (A–B)	400	0.054	0.073	0.062	0.581
SNN (A–B–C)	100	0.163	0.725	0.277	0.142
SNN (A–B–C)	400	0.079	0.121	0.096	0.600

Observaciones clave

- Kernels óptimos: `mexican_hat` , `laplacian`
- Procesamiento preferido: `weighted_sum` , `max`
- **Tendencia inversa:** $n_{100} > n_{200} > n_{400}$ (sobreajuste en redes grandes)

Resultados — Dataset Callt2

Rendimiento estable y robusto

Modelo	N	Precisión	Recall	F1	MSE
SNN (A-B)	100	0.160	0.472	0.239	0.790
SNN (A-B-C)	100	0.263	1.000	0.416	0.737
SNN (A-B-C)	200	0.264	1.000	0.417	0.734
SNN (A-B-C)	400	0.264	0.994	0.417	0.730

Observaciones clave

- **Recall** $\approx$ 100% → estrategia conservadora (detecta todas las anomalías)
- Kernels óptimos: `mexican_hat`, `gaussian` (tamaño 5-7)
- Procesamiento preferido: `direct`
- **Estabilidad:** F1 constante independientemente del tamaño de red

Resultados — Comparación con Baselines TSFEDL

Modelo	F1 (IOPS)	F1 (Callt2)
SNN (A-B)	0.062	0.239
SNN (A-B-C)	0.277	0.417
TSFEDL-OhShuLih	0.436	0.704
TSFEDL-KhanZulfiqar	0.410	0.704
TSFEDL-ZhengZhenyu	0.412	0.704
TSFEDL-WeiXiaoyan	0.380	0.679

Interpretación

- Los modelos TSFEDL superan a las SNN en F1-score absoluto
- **Sin embargo:** Las SNN ofrecen ventajas potenciales en eficiencia energética
- La brecha se reduce significativamente con la arquitectura híbrida

Discusión — Análisis de Parámetros

Parámetros más influyentes (según Optuna)

1. Parámetros neuronales (mayor impacto):

- `threshold` $\in [-66.8, -67.7]$
- `decay` $\in [73.6, 139.8]$

2. Parámetros de plasticidad:

- `nu1` , `nu2`

3. Parámetros convolucionales (impacto secundario):

- `kernel_size` , `sigma`

La dinámica LIF sigue siendo el **factor clave** del rendimiento

Discusión — Implicaciones Prácticas

Potencial para aplicaciones reales

- ✓ Alto Recall (99.9%) en CalIt2 → Crucial para evitar fallos no detectados
- ✓ Arquitectura basada en impulsos → Compatible con hardware neuromórfico
- ✓ Naturaleza dispersa → Eficiencia en procesamiento edge

Limitaciones actuales

- ⚠ Baja precisión → Requiere post-procesado para reducir falsas alarmas
- ⚠ Validación energética pendiente → Solo estimaciones teóricas (MACs)
- ⚠ Ejecución en CPU → Sin aceleración GPU por incompatibilidades

Conclusiones

Principales contribuciones

1.  Arquitectura híbrida SNN-CNN con capa convolucional parametrizable
2.  Flujo de preprocesamiento reproducible adaptado a SNNs
3.  Evidencia empírica de mejora en datasets desbalanceados (4.6x en IOPS)
4.  Metodología comparativa reutilizable para trabajos futuros

Conclusión principal

Las arquitecturas híbridas SNN-CNN ofrecen un **equilibrio interesante** entre rendimiento y eficiencia computacional, posicionándose como alternativa viable para **edge computing** y entornos con restricciones energéticas.

Trabajos Futuros

Líneas prioritarias

Área	Propuesta
Hardware neuromórfico	Validación en Intel Loihi 2, SpiNNaker 2, BrainScaleS-2
Métricas energéticas	Joules/inferencia, mW promedio, latencia por ventana
Optimización multiobjetivo	F1 + MACs con NSGA-II
Validación cruzada temporal	Rolling-origin, nested backtesting
Datasets industriales	Señales de vibración, temperatura, presión

Despliegue neuromórfico

- Monitorización de dispersidad
- Re-calibración automática de umbrales
- Empaquetado para microcontroladores SNN nativos

¡Gracias por su atención!

¿Preguntas?

Javier González Santos

Máster en Ingeniería Informática

Universidad de Jaén

Referencias Bibliográficas

- Cherdo et al. (2023) — Time series anomaly detection with SNNs
- Kshirasagar et al. (2024) — Auditory cortex-inspired models
- Sanaullah et al. (2024) — Hybrid SNN-CNN architectures
- Vázquez et al. (2024) — Vacuum systems monitoring with SNNs
- Aguilera-Martos et al. (2023) — TSFEDL library

Ver bibliografía completa en el documento de memoria